Redes y sistemas complejos

Fundamentos, modelos, dinámica y aprendizaje en grafos

Cristian Candia, Ph.D.

Computational Research in Social Science Lab
Instituto de Data Science, Facultad de Ingeniería, Universidad del Desarrollo
Northwestern Institute on Complex Systems (NICO), Northwestern University

Monografía del curso de Redes y Sistemas Complejos
Semestre 1, 2026
Edición 0.96 (revisión curricular y metodológica)

15 de julio de 2026

Contacto: crcandiav@gmail.com

© 2026 Cristian Candia, Ph.D.. Todos los derechos reservados.

Presentación

Esta monografía introduce la ciencia de redes como una disciplina que conecta representación, inferencia y dinámica. El punto de partida es una decisión de modelado: qué entidades se representan como nodos y qué relación se codifica como arista. A partir de esa decisión se estudian la estructura microscópica y mesoscópica, los modelos generativos, los procesos de contagio, el aprendizaje sobre grafos y los problemas de validación, causalidad, privacidad y equidad. El texto combina la tradición matemática de la disciplina con criterios de análisis empírico y evaluación reproducible (Newman, 2018; Barabási and Pósfai, 2016; Menczer et al., 2020).

La notación se introduce de manera acumulativa. Las afirmaciones empíricas se distinguen de los ejemplos de diseño y de las consecuencias que se derivan de un modelo. Esta distinción resulta central en datos relacionales: una propiedad observada puede depender tanto del sistema como del mecanismo de muestreo, de la definición del enlace o de la resolución temporal elegida.

Ruta de lectura del curso

El curso avanza en ocho unidades. La monografía conserva esa secuencia y separa dos profundizaciones que no son requisito para completar la ruta central:

U1 — Fundamentos y modelamiento. Capítulos 1 y 2: definición de nodos y aristas, trazabilidad, matrices, pesos y auditoría estructural.

U2 — Redes bipartitas. Capítulo 2: matriz biadyacente, proyecciones, normalización y nulos que controlan actividad.

U3 — Features y segmentación. Capítulo 3: centralidades como variables, sensibilidad, redundancia y estabilidad de rankings.

U4 — Modelos generativos y nulos. Capítulos 4 y 6: ER, WS, BA, configuración, simulación y diagnóstico de modelos.

U5 — Mesoestructura. Capítulo 5: modularidad, Louvain, Leiden, núcleo–periferia, k-core y validación de particiones.

U6 — Procesos en redes. Capítulo 7: SIS, SIR, umbrales, temporalidad e intervenciones.

U7 — Inferencia, evaluación y ética. Capítulos 6, 11 y 13: dependencia, permutaciones, leakage, incertidumbre, privacidad y comunicación responsable.

U8 — Industria y Graph ML. Capítulos 10–12: embeddings, GNN, baselines, evaluación y criterios para decidir si la topología agrega valor.

Los capítulos 8 y 9 desarrollan causalidad con interferencia y redes multicapa. Pueden leerse después de U7 como extensiones avanzadas; no se requieren para seguir los laboratorios básicos.

Índice general

Presentación **i**

Ruta de lectura del curso i

1. Redes como representación de sistemas complejos **1**

1.1. Introducción 1
1.2. ¿Qué es (y qué no es) una red? 1
1.3. Redes como modelos de sistemas complejos 2
1.4. Escalas de análisis: micro, meso y macro 2
1.5. Tipos de redes y ejemplos 3
1.6. De registros a una red auditable 4
1.6.1. Controles mínimos de construcción 4
1.7. Importancia de la representación en redes 5
1.8. Conexión con el aprendizaje en redes 5
1.9. Redes como objetos epistemológicos 5
1.10. Conclusión 5

2. Estructura básica de las redes **7**

2.1. Introducción 7
2.2. Distribución de grados 7
2.3. Matriz de adyacencia y grafos dirigidos 7
2.4. Redes ponderadas 8
2.5. Redes bipartitas 8
2.5.1. Matriz biadyacente y grados por modo 8
2.5.2. Proyecciones y ponderación 8
2.5.3. Nulos bipartitos y significancia del solapamiento 9
2.5.4. Cuándo conservar la red bipartita 9
2.6. Coeficiente de clustering y estructura local 9
2.7. Caminos, distancias y mundo pequeño 10
2.8. Centralidades y medidas de importancia 10
2.8.1. Centralidad de grado 10
2.8.2. Centralidad de intermediación 10
2.8.3. Centralidad eigenvectorial 10
2.8.4. Centralidad de cercanía 11
2.9. Laplaciano de grafos y operadores espectrales 11
2.9.1. Definición 11
2.9.2. Interpretación física (difusión, suavizado) 11

2.9.3. Relación con conectividad y cortes . . . 11
2.9.4. Laplaciano normalizado . . . 12
2.10. Conclusiones . . . 12

3. Centralidades como features: medición, sensibilidad y desigualdad 13
3.1. De una métrica a una variable defendible . . . 13
3.2. Elegir la familia de features según el proceso . . . 13
3.3. Pesos, distancias y ventanas . . . 14
3.4. Construcción de un feature store por nodo . . . 14
3.5. Redundancia y estabilidad de rankings . . . 15
3.6. Centralidad, poder e inequidad . . . 15
3.7. Features sin leakage . . . 15
3.8. Cierre . . . 16

4. Modelos generativos, nulos y baselines 17
4.1. Tres usos que no deben confundirse . . . 17
4.2. Erdős–Rényi: independencia de aristas . . . 17
4.3. Modelo de configuración: controlar el grado . . . 17
4.4. Watts–Strogatz: atajos sobre orden local . . . 18
4.5. Barabási–Albert: crecimiento y ventaja acumulativa . . . 18
4.6. Calibración y model checking . . . 18
4.7. Diseñar el nulo desde la pregunta . . . 19
4.8. Protocolo reproducible de comparación . . . 19

5. Mesoestructura: comunidades, núcleos y roles 21
5.1. La escala intermedia no es una partición única . . . 21
5.2. Modularidad y parámetro de resolución . . . 21
5.3. Louvain, Leiden y estabilidad algorítmica . . . 21
5.3.1. Barrido de resolución y consenso . . . 22
5.4. Descomposición k-core y core–periphery . . . 22
5.5. Roles y equivalencias . . . 23
5.6. Validación externa y límites de interpretación . . . 23

6. Inferencia estadística en redes complejas 24
6.1. El objeto inferencial . . . 24
6.2. Dependencia estructural y límites del paradigma i.i.d. . . . 24
6.3. Modelos nulos como hipótesis estructurales . . . 25
6.3.1. Erdős–Rényi . . . 25
6.3.2. Modelo de configuración . . . 25
6.3.3. Modelo de bloques estocásticos . . . 25
6.4. Contrastes y cuantificación de incertidumbre . . . 25
6.4.1. Pruebas por aleatorización . . . 25
6.4.2. Modularidad y centralidad . . . 26
6.4.3. Bootstrap y simulación paramétrica . . . 26
6.5. Redes incompletas y sensibilidad estructural . . . 26
6.6. Criterio de cierre inferencial . . . 26

7. Procesos sobre redes **27**
7.1. Difusión y contagio en redes heterogéneas . . . 27
7.1.1. Intuición: por qué la topología cambia la dinámica . . . 27
7.1.2. Modelos SIS y SIR en redes: definición microscópica . . . 27
7.1.3. Campo medio heterogéneo y segundo momento del grado . . . 28
7.1.4. Formulación espectral: umbral como función del radio espectral . . . 28
7.1.5. Más allá del caso ideal: correlaciones, modularidad y redes temporales . 29
7.2. Influencia de la centralidad en la difusión . . . 30
7.2.1. La importancia depende del proceso . . . 30
7.2.2. Influencia como problema de intervención: inmunización e influencia máxima . . . 30
7.2.3. Centralidades para contagio: grado vs. coreness (k-core) . . . 30
7.2.4. Centralidad como modelo de flujo: cuándo sirve betweenness . . . 30
7.3. Redes con estructura de mundo pequeño . . . 31
7.3.1. Intuición: atajos reducen tiempos característicos . . . 31
7.3.2. Watts–Strogatz y variantes analíticas . . . 31
7.3.3. Redes temporales vs redes agregadas . . . 31
7.3.4. Caminos temporales . . . 31
7.3.5. Consecuencias prácticas (orden importa) . . . 31
7.4. Qué puede sostener una conclusión sobre difusión . . . 32

8. Causalidad, interferencia y efectos de red **33**
8.1. Por qué una red cambia la pregunta causal . . . 33
8.2. Mapas de exposición . . . 33
8.3. Diseños de intervención . . . 34
8.3.1. Aleatorización individual y saturación . . . 34
8.3.2. Aleatorización por conglomerados . . . 34
8.3.3. Selección de semillas . . . 34
8.4. Por qué una red observacional no identifica influencia . . . 34
8.5. Estimación y diagnóstico . . . 35
8.6. Alcance de las conclusiones . . . 35

9. Redes multicapa y multiplex **36**
9.1. Cuándo una capa no basta . . . 36
9.2. Representación algebraica . . . 36
9.2.1. Matriz supra-adyacente . . . 36
9.2.2. Comunidades multicapa . . . 37
9.3. Procesos dinámicos en múltiples capas . . . 37
9.3.1. Difusión acoplada . . . 37
9.3.2. Contagio . . . 37
9.3.3. Redes temporales . . . 37
9.4. Decisiones de modelado y validación . . . 38
9.5. Identificabilidad, cobertura y escala . . . 38

10. Aprendizaje en redes **39**
10.1. Representaciones y tareas en grafos . . . 39
10.1.1. Intuición: ¿por qué aprender sobre grafos? . . . 39
10.1.2. Fundamentos matemáticos de las representaciones . . . 39
10.2. Embeddings basados en paseos aleatorios . . . 40
10.2.1. Intuición: analogía entre grafos y lenguaje . . . 40
10.2.2. Formulación matemática: DeepWalk y skip-gram . . . 40
10.3. Redes neuronales de grafos y message passing . . . 40
10.3.1. Intuición: operadores locales y acoplamiento a la estructura . . . 40
10.3.2. Formulación general de message passing . . . 41
10.3.3. Consideraciones avanzadas . . . 41
10.4. Cuándo Graph ML agrega valor . . . 42
10.4.1. Casos industriales y criterio de éxito . . . 43
10.5. Tareas supervisadas y no supervisadas . . . 43
10.6. Cierre: representación antes que arquitectura . . . 44

11. Evaluación y validación de modelos en grafos **45**
11.1. La partición define la generalización . . . 45
11.2. Construcción del grafo sin filtración . . . 45
11.3. Regímenes de partición . . . 45
11.3.1. Clasificación transductiva de nodos . . . 45
11.3.2. Clasificación inductiva . . . 46
11.3.3. Predicción de enlaces . . . 46
11.3.4. Grafos temporales . . . 46
11.4. Métricas ligadas a la tarea . . . 46
11.4.1. Clasificación de nodos . . . 46
11.4.2. Predicción de enlaces . . . 46
11.5. Baselines y ablaciones . . . 47
11.6. Variabilidad y comparación . . . 47
11.7. Ficha mínima de reporte . . . 47

12. Diseño de estudios integrados en ciencia de redes **49**
12.1. De una pregunta sustantiva a una red auditable . . . 49
12.2. Protocolo común . . . 49
12.3. Caso I: telemetría de ciberseguridad . . . 50
12.3.1. Representación . . . 50
12.3.2. Preguntas y baselines . . . 50
12.3.3. Conclusión permitida . . . 50
12.4. Caso II: copresencia inferida mediante WiFi . . . 50
12.4.1. De eventos técnicos a vínculos sociales . . . 50
12.4.2. Temporalidad y privacidad . . . 51
12.5. Caso III: trayectorias educativas . . . 51
12.5.1. Estructura bipartita . . . 51
12.5.2. Alcance inferencial . . . 51
12.6. Caso IV: compras públicas . . . 51
12.6.1. Red temporal y ponderada . . . 51

12.6.2. Detección sin acusación 52
12.7. Tres extensiones para Graph ML industrial 52
12.7.1. Fraude coordinado 52
12.7.2. Recomendación 52
12.7.3. Bioinformática 52
12.8. Síntesis transversal 53

13.Ética y privacidad en redes **54**
13.1. Medir redes como acto de poder 54
13.1.1. Intuición: de lo local a lo global 54
13.1.2. De la re-identificación a la manipulación de algoritmos 54
13.2. Privacidad, homofilia y filtrado 54
13.2.1. Homofilia y fuga de información 54
13.2.2. Ataques de inferencia y modelos de filtrado 54
13.3. Buenas prácticas y principios éticos 55
13.3.1. Anonimización y minimización de daños 55
13.3.2. Consentimiento informado y transparencia 55
13.3.3. Equidad algorítmica y mitigación de sesgos 55
13.3.4. Directrices institucionales y deontología 55
13.4. Ética del aprendizaje automático en grafos 56
13.5. Conclusiones 56

Capítulo 1

Redes como representación de sistemas complejos

1.1. Introducción

La ciencia de redes estudia sistemas en los que las relaciones son parte del fenómeno y no un residuo de los datos. Interacciones sociales, reacciones bioquímicas, rutas de transporte y flujos de información pueden describirse con un mismo lenguaje matemático, aunque no con la misma interpretación. Esa combinación de generalidad formal y especificidad sustantiva explica el carácter interdisciplinario del campo (Menczer et al., 2020). Este capítulo fija la unidad básica de análisis. Su tesis es más exigente: construir una red ya decide qué relación merece ser modelada y cuáles quedan fuera.

1.2. ¿Qué es (y qué no es) una red?

Una red o *grafo* es una estructura matemática definida como un par $G = (V, E)$, donde V es el conjunto de *nodos* o vértices y E es el conjunto de *enlaces* o aristas. Cada enlace $e \in E$ conecta un par de nodos y puede ser *dirigido* (si distingue una fuente y un destino) o *no dirigido*. El grafo puede representarse mediante su *matriz de adyacencia* $A \in \mathbb{R}^{n\times n}$, donde $n = |V|$ es el número de nodos y

$$A_{ij} = \begin{cases} 1, & \text{si existe una arista de } i \text{ a } j, \\ 0, & \text{en caso contrario,} \end{cases} \tag{1.1}$$

para un grafo no ponderado; si los enlaces llevan pesos w_{ij}, entonces $A_{ij} = w_{ij}$. Un grafo es el objeto matemático. Una red lo vincula con entidades e interacciones observadas. El significado de la arista delimita las interpretaciones válidas.

El *grado* k_i de un nodo i en un grafo no dirigido se define como el número de enlaces incidentes en i y puede calcularse a partir de la matriz de adyacencia como

$$k_i = \sum_{j=1}^{n} A_{ij} = \sum_{j=1}^{n} A_{ji}, \tag{1.2}$$

para grafos no dirigidos. En grafos dirigidos se distingue entre *grado de entrada* $k_i^{\text{in}} = \sum_j A_{ji}$ y

grado de salida $k_i^{\text{out}} = \sum_j A_{ij}$. El vector $(k_1, \ldots, k_n)$ captura la heterogeneidad estructural: en muchas redes reales aparecen nodos con grados muy altos (*hubs*) y la distribución de grados presenta colas pesadas, lo que implica la presencia de nodos dominantes (Rodrigues, 2018; Barabási and Pósfai, 2016). Esta heterogeneidad tiene importantes consecuencias dinámicas, como veremos en secciones posteriores.

1.3. Redes como modelos de sistemas complejos

Los sistemas complejos son aquellos formados por muchos componentes interactuantes cuya dinámica colectiva no puede inferirse fácilmente a partir del comportamiento individual. Ejemplos incluyen ecosistemas, mercados financieros y redes neuronales. Una característica fundamental de estos sistemas es la *no linealidad*: pequeñas perturbaciones pueden provocar efectos macroscópicos. Modelar un sistema complejo como una red permite representar explícitamente sus patrones de interacción y estudiar cómo estos patrones influyen en procesos dinámicos como la difusión, la sincronización o la cooperación.

En una red heterogénea, la distribución de grados $P(k)$ resume cuántos nodos tienen grado k. Algunas redes presentan colas pesadas y, en ciertos rangos, son compatibles con $P(k) \propto k^{-\gamma}$ para $k \geq k_0$. La etiqueta *escala libre* exige estimación y contraste; una cola visualmente recta en ejes logarítmicos no basta. Para un proceso SIS no correlacionado, la aproximación de campo medio heterogéneo produce

$$\lambda_c \approx \mu \frac{\langle k \rangle}{\langle k^2 \rangle}, \tag{1.3}$$

donde λ es la tasa de transmisión y μ la de recuperación. Si el segundo momento crece sin cota en una secuencia idealizada de redes, el umbral asintótico puede tender a cero. Redes finitas, correlaciones de grado, clustering y cambios de comportamiento alteran esa conclusión (Pastor-Satorras et al., 2015).

Representar un sistema como red selecciona relaciones y descarta otras. Esa operación convierte registros locales en una visión global que los participantes no poseen y permite inferir atributos a través de vecinos (Clauset, 2022). La ganancia analítica y el riesgo de privacidad nacen de la misma estructura.

1.4. Escalas de análisis: micro, meso y macro

Representar un sistema como red permite estudiar fenómenos a distintas escalas:

1. **Escala micro.** Se centra en propiedades locales de los nodos y los enlaces. Aquí se analizan métricas como el grado, la fuerza (suma de pesos en redes ponderadas) o la *centralidad de intermediación*, que mide la fracción de caminos mínimos que pasan por un nodo. Para un nodo i, la centralidad de intermediación se define como

$$C_B(i) = \sum_{s \neq i \neq t} \frac{\sigma_{st}(i)}{\sigma_{st}}, \tag{1.4}$$

donde σ_{st} es el número total de caminos geodésicos entre s y t y $\sigma_{st}(i)$ es el número de estos caminos que pasan por i. Esta medida sirve para identificar nodos que actúan como *puentes* entre comunidades distintas.

2. **Escala meso.** Analiza subestructuras emergentes, como *comunidades* (grupos de nodos densamente conectados), *motivos* (patrones recurrentes de pocas aristas) o *núcleo–periferia*. Las comunidades permiten inferir organización funcional y roles sociales; sin embargo, no toda partición comunitaria es significativa y su interpretación depende del contexto (Fortunato, 2010). En grafos bipartitos (p.ej., autores y artículos) es frecuente proyectar a un grafo unipartito; dicha proyección puede inducir sesgos al sobrerrepresentar nodos muy activos.

3. **Escala macro.** Considera propiedades globales, como la distribución de grados, la fracción de nodos conectados en el *componente gigante*, el diámetro (la longitud máxima de un camino geodésico) o la *longitud de camino medio*. Otra medida global es el *coeficiente de clustering* promedio, definido como

$$C = \frac{1}{n} \sum_{i=1}^{n} \frac{2T_i}{k_i(k_i - 1)}, \tag{1.5}$$

donde T_i es el número de triángulos que incluyen al nodo i. El coeficiente C mide la tendencia de los amigos de mis amigos a ser amigos entre sí y es elevado en redes sociales reales, a diferencia de grafos aleatorios en los que $C \sim \langle k \rangle / n$.

El análisis a múltiples escalas proporciona una comprensión integral: identifica actores clave, patrones de organización y propiedades emergentes que no son evidentes al examinar los componentes por separado.

1.5. Tipos de redes y ejemplos

La diversidad de aplicaciones de la ciencia de redes implica que las estructuras pueden clasificarse en varios tipos según el dominio:

- **Redes sociales.** Representan interacciones entre personas o grupos, como relaciones de amistad, colaboración académica o comunicación en redes sociales en línea. Los nodos suelen ser individuos y las aristas, interacciones. Estas redes presentan alto clustering y distribuciones de grado heterogéneas.

- **Redes tecnológicas.** Incluyen redes de telecomunicaciones (Internet, telefonía), redes eléctricas, redes de transporte o infraestructuras logísticas. Su análisis permite estudiar eficiencia, robustez frente a fallos y optimización de rutas.

- **Redes biológicas.** Comprenden redes de interacción entre proteínas, redes metabólicas, sinapsis neuronales y redes de ecosistemas. Estas redes sirven para entender procesos biológicos y desarrollar aplicaciones en bioinformática.

- **Redes de información.** Conectan conceptos o documentos mediante relaciones semánticas o de citación: por ejemplo, la red de citas académicas es un grafo dirigido en el que cada artículo cita a otros trabajos. Los nodos con alto grado entrante suelen actuar como hubs de conocimiento.

Las fronteras entre categorías dependen de la pregunta. Las preferencias de postulantes permiten construir una red de programas universitarios (Candia et al., 2019a); registros de

copresencia espacial permiten aproximar redes informales de trabajadores de plataformas (Pilatti et al., 2023); y redes de conceptos extraídas de texto permiten estudiar conflictos o deliberación política (Herrera et al., 2019; Raveau et al., 2024). En cada caso, la arista es una operación de medición distinta.

1.6. De registros a una red auditable

La mayoría de las redes empíricas nace en una tabla de eventos. Una fila puede registrar que la persona i envió un mensaje a j en el tiempo t, que una empresa participó en una licitación o que un estudiante seleccionó un programa. Convertir esas filas en aristas exige reglas que puedan ejecutarse de nuevo y producir el mismo grafo. La construcción de redes de colaboración científica muestra una decisión aparentemente menor con efectos macroscópicos: contar cada artículo como una relación binaria o ponderar por tamaño del equipo produce redes distintas (Newman, 2001).

Sea $\mathcal{D}$ una tabla de eventos (s_r, d_r, t_r, x_r), con origen, destino, tiempo y atributos. Para una ventana Δ, un peso de frecuencia puede definirse como

$$w_{ij}^{(\Delta)} = \sum_{r \in \mathcal{D}} \mathbf{1}\{s_r = i,\ d_r = j,\ t_r \in \Delta\}. \tag{1.6}$$

La ecuación parece inocua, pero fija qué eventos se suman, cómo se resuelven identificadores y qué ocurre con eventos repetidos. Un peso monetario, una duración y un conteo no son versiones intercambiables de la misma relación.

1.6.1. Controles mínimos de construcción

Antes de calcular una métrica deben registrarse, al menos, los siguientes controles:

1. **Identidad y granularidad.** Verificar unicidad, cambios de identificador, entidades fusionadas y unidades que aparecen bajo varios nombres.
2. **Duplicados.** Distinguir una repetición espuria de eventos legítimamente reiterados. Eliminar filas idénticas sin revisar su origen puede borrar frecuencia real.
3. **Autolazos y multiaristas.** Declarar si $i \to i$ tiene significado y si varias interacciones se conservan como multigrafo o se agregan en un peso.
4. **Dirección.** No simetrizar pagos, citas o mensajes sin una razón sustantiva. La reciprocidad observada después de simetrizar carece de interpretación.
5. **Cobertura.** Informar nodos aislados, componentes, periodos sin observación y entidades que el mecanismo de recolección no puede detectar.
6. **Escala temporal.** Comparar ventanas plausibles. Una agregación extensa puede crear caminos entre eventos que nunca coexistieron.

El resultado de esta etapa no es solo un archivo de aristas. Es un registro de procedencia: fuente, fecha de extracción, filtros, reglas de agregación y conteos antes y después de cada transformación. Sin ese registro, dos analistas pueden usar los mismos datos y estudiar objetos distintos sin advertirlo.

1.7. Importancia de la representación en redes

La representación determina qué dependencias quedan disponibles para el análisis. Si dos personas se conectan por copresencia, una arista significa coincidencia espacial; si se conectan por mensajes, significa comunicación registrada. La misma pareja puede estar unida en una red y ausente en otra sin contradicción. Cambió el instrumento.

Los modelos relacionales explotan esa decisión como sesgo inductivo: vecinos, caminos o subgrafos se tratan como fuentes de información (Hamilton, 2020). Una arista mal definida no añade ruido inocuo. Puede propagar una asociación espuria por varias capas de una GNN, alterar una comunidad o convertir actividad en aparente prestigio. El capítulo 10 desarrolla las operaciones de message passing; aquí basta una regla: la arquitectura no puede recuperar el significado que se perdió al construir el grafo.

La estructura también revela información sobre personas que nunca entregaron un atributo. La homofilia permite inferir preferencias a partir de vecinos, y un patrón de conexiones puede actuar como identificador (Clauset, 2022). Cobertura, consentimiento y control de acceso pertenecen al diseño de la red, no a una revisión ética posterior.

1.8. Conexión con el aprendizaje en redes

Las técnicas de *graph representation learning* mapean nodos o grafos a espacios de menor dimensión bajo un objetivo definido. Los paseos aleatorios, como *DeepWalk* o *node2vec*, convierten vecindarios en secuencias; las GNN agregan mensajes a lo largo de aristas. Se aplican a clasificación, predicción de enlaces y representación de grafos completos (Hamilton, 2020; Sánchez-Lengeling et al., 2021). Su evaluación comienza antes del entrenamiento: debe probar si la topología agrega señal frente a atributos y features estructurales más simples.

1.9. Redes como objetos epistemológicos

La matriz final suele ocultar el camino que la produjo. Cuando una proyección, un umbral o una ventana dejan de verse, la red se reifica: parece un objeto encontrado en vez de una medición construida. Esa pérdida de procedencia vuelve difícil distinguir un patrón del sistema de un patrón introducido por el analista.

Dos problemas siguen. Las observaciones comparten nodos y aristas, de modo que la independencia no puede darse por supuesta. Y la asociación entre vecinos admite varias historias: influencia, selección, contexto compartido o error de medición. Los capítulos de inferencia y causalidad tratan estas alternativas por separado. El rigor comienza conservando visible la cadena que une registro, red, estimando y conclusión.

1.10. Conclusión

Una red conserva dependencias que una tabla de unidades aisladas perdería. Esa ventaja analítica obliga a declarar el significado de nodos, aristas, pesos y ventanas temporales. La matriz de adyacencia, el grado y el clustering describen aspectos distintos de esa representación; ninguno corrige una arista mal definida. Los capítulos siguientes parten de este criterio para estudiar estructura, modelos generativos, dinámica e inferencia. La pregunta que los organiza

no es solo qué puede calcularse sobre un grafo, sino qué permite concluir la red que fue efectivamente observada.

Capítulo 2

Estructura básica de las redes

2.1. Introducción

La estructura restringe qué trayectorias puede recorrer un proceso y qué partes del sistema permanecen conectadas ante una perturbación. Distribución de grados, matrices, pesos, bipartición, clustering, distancias y Laplacianos describen restricciones distintas; ninguna cifra resume por sí sola la topología.

2.2. Distribución de grados

Sea $G = (V, E)$ un grafo no dirigido con $n = |V|$ nodos. El *grado* de un nodo i se define como en la ecuación 1.2, es decir, $k_i = \sum_{j=1}^{n} A_{ij}$, donde A es la matriz de adyacencia. La *distribución de grados* $P(k)$ es la probabilidad de que un nodo elegido al azar tenga grado k. En términos discretos, si N_k es el número de nodos con grado k, entonces $P(k) = N_k/n$, con $\sum_k P(k) = 1$(Barabási and Pósfai, 2016). Esta distribución constituye un resumen de la heterogeneidad del grafo: redes homogéneas tienen distribuciones concentradas alrededor de un valor medio, mientras que redes heterogéneas exhiben colas pesadas, con hubs de alto grado. La forma de $P(k)$ influye en la conectividad global, la robustez y la propagación de procesos en la red (Barabási and Pósfai, 2016).

La distribución de grados condiciona la respuesta a eliminaciones de nodos. En modelos con colas pesadas, los fallos uniformes suelen alcanzar nodos de grado bajo, mientras una estrategia dirigida a hubs puede fragmentar la red con mayor rapidez. La magnitud del efecto depende del tamaño finito, las correlaciones, la modularidad y la regla de ataque; no se deduce solo de ajustar $P(k) \propto k^{-\gamma}$.

2.3. Matriz de adyacencia y grafos dirigidos

La descripción completa de un grafo puede codificarse en su *matriz de adyacencia* $A \in \mathbb{R}^{n\times n}$. Para un grafo no dirigido y no ponderado se define

$$A_{ij} = \begin{cases} 1, & \text{si existe una arista entre } i \text{ y } j, \\ 0, & \text{en caso contrario,} \end{cases} \tag{2.1}$$

de modo que A es simétrica. En grafos dirigidos se utiliza una convención similar, pero el hecho de que la arista vaya de i a j se refleja en la entrada A_{ij}; por tanto A puede no ser simétrica. La matriz de adyacencia permite expresar muchas propiedades locales y globales de la red de forma algebraica. Por ejemplo, el grado de salida de un nodo i en un grafo dirigido es $k_i^{\text{out}} = \sum_j A_{ij}$ y el grado de entrada es $k_i^{\text{in}} = \sum_j A_{ji}$ (Barabási and Pósfai, 2016).

El uso de A facilita el cómputo de caminos de longitud l: la entrada $(A^l)_{ij}$ cuenta el número de caminos de longitud l que conectan i con j. Además, muchas medidas de centralidad se definen a partir de funciones de A, como la centralidad eigenvectorial (véase la Sección 2.8).

2.4. Redes ponderadas

En numerosas aplicaciones los enlaces llevan asociada una intensidad o peso w_{ij} que cuantifica la fortaleza de la relación (p.ej., número de correos entre dos personas, capacidad de una línea de transmisión). Un *grafo ponderado* se representa mediante una matriz W cuyas entradas W_{ij} son los pesos. Para redes ponderadas, el grado generalizado de un nodo puede definirse como la *fuerza* $s_i = \sum_j W_{ij}$, que mide la suma de los pesos de las aristas incidentes. La decisión de ignorar o no los pesos tiene consecuencias analíticas: simplificar una red ponderada a un grafo no ponderado pierde información sobre la intensidad de las interacciones. Barabási and Pósfai (2016) advierten que muchas redes reales son inherentemente ponderadas y que el análisis puramente topológico puede ser insuficiente (Barabási and Pósfai, 2016).

2.5. Redes bipartitas

Un *grafo bipartito* $G = (U, V, E)$ separa dos clases de nodos y admite aristas solo entre clases. Autores–artículos, empresas–licitaciones y postulantes–programas son estructuras bipartitas antes de cualquier proyección. Esta representación conserva quién participó en qué evento; una red unipartita retiene únicamente coincidencias entre participantes (Latapy et al., 2008).

2.5.1. Matriz biadyacente y grados por modo

Con $|U| = n$ y $|V| = m$, la matriz biadyacente $B \in \{0,1\}^{n \times m}$ se define por $B_{i\alpha} = 1$ cuando $(i, \alpha) \in E$. Los grados deben interpretarse por separado:

$$k_i^U = \sum_{\alpha=1}^{m} B_{i\alpha}, \qquad k_\alpha^V = \sum_{i=1}^{n} B_{i\alpha}. \tag{2.2}$$

En compras públicas, k_i^U puede contar procesos en los que participa una empresa, mientras k_α^V cuenta oferentes de una licitación. Ambos márgenes generan heterogeneidad; ignorar uno de ellos atribuye a afinidad lo que puede ser simple actividad.

2.5.2. Proyecciones y ponderación

La proyección ponderada sobre U es

$$P_U = BB^{\mathsf{T}}, \qquad (P_U)_{ij} = \sum_{\alpha} B_{i\alpha} B_{j\alpha}. \tag{2.3}$$

La diagonal $(P_U)_{ii} = k_i^U$ se elimina si se desea un grafo simple. La proyección sobre V es $P_V = B^\top B$. El peso bruto cuenta vecinos compartidos, pero favorece nodos con alta actividad. Dos normalizaciones frecuentes son

$$J_{ij} = \frac{|N(i) \cap N(j)|}{|N(i) \cup N(j)|}, \qquad S_{ij}^{\cos} = \frac{(P_U)_{ij}}{\sqrt{k_i^U k_j^U}}, \tag{2.4}$$

donde J_{ij} es Jaccard y $S_{ij}^{\cos}$ es similitud coseno. No existe una normalización universal: Jaccard penaliza el tamaño de la unión; coseno compara el solapamiento con una escala geométrica. La elección debe corresponder a la pregunta y acompañarse de sensibilidad (Chung et al., 2019).

Proyectar también cambia la topología. Un nodo $\alpha \in V$ conectado a muchos nodos de U induce un clique en P_U, elevando densidad y clustering aunque no exista interacción directa entre sus miembros. El problema no se resuelve aplicando un umbral después de mirar la red: el umbral selecciona una definición de relación y debe validarse como tal.

2.5.3. Nulos bipartitos y significancia del solapamiento

La pregunta inferencial es si el solapamiento observado excede lo esperado dadas las oportunidades de coincidencia. Un nulo bipartito puede permutar aristas mediante *double-edge swaps* que preserven los grados de ambos modos. Para una estadística T_{ij}, por ejemplo J_{ij}, las simulaciones producen

$$Z_{ij} = \frac{T_{ij}^{\text{obs}} - \mathbb{E}_0[T_{ij}]}{\text{sd}_0(T_{ij})}, \qquad p_{ij} = \frac{1 + \sum_{b=1}^{R} \mathbf{1}\{T_{ij}^{(b)} \geq T_{ij}^{\text{obs}}\}}{R+1}. \tag{2.5}$$

El nulo debe preservar las restricciones que generan oportunidades reales; de otro modo, una comparación aleatoria puede ser tan engañosa como la proyección bruta (Gotelli, 2000). En colicitación, el control simultáneo de actividad de empresas y tamaño de licitaciones separa coocurrencias esperables de pares inusuales (Lyra et al., 2021; Sturm et al., 2025).

2.5.4. Cuándo conservar la red bipartita

Una proyección es justificable cuando el objeto de estudio son relaciones entre nodos de un mismo modo y existe una regla defendible para traducir coparticipación en proximidad. Si la pregunta involucra simultáneamente actores y eventos, conviene mantener B o usar un modelo de dos modos. La proyección pierde qué evento originó cada arista, altera las distancias e introduce triángulos mecánicos. El análisis del *Higher Education Space* ilustra una proyección útil porque la afinidad entre programas se valida contra trayectorias y resultados externos (Candia et al., 2019a, 2025).

2.6. Coeficiente de clustering y estructura local

El *coeficiente de clustering* mide la propensión de los vecinos de un nodo a estar conectados entre sí, es decir, la densidad de triángulos alrededor de un nodo. Para un nodo i de grado $k_i \geq 2$, el coeficiente de clustering local se define como

$$C_i = \frac{2T_i}{k_i(k_i - 1)}, \tag{2.6}$$

donde T_i cuenta triángulos incidentes en i (Barabási and Pósfai, 2016). El promedio $\langle C \rangle = n^{-1} \sum_i C_i$ resume cierre local, pero mezcla nodos de grados y componentes distintos. En ER, $\langle C \rangle \approx p$; en muchas redes sociales el valor observado es mayor que ese baseline. El modelo de Watts–Strogatz muestra que pocos atajos pueden reducir distancias sin destruir de inmediato el clustering (Watts and Strogatz, 1998).

2.7. Caminos, distancias y mundo pequeño

La distancia $d(i, j)$ es la longitud del camino más corto. El diámetro toma el máximo entre pares conectados y la longitud media promedia esas distancias. En un grafo desconectado, ambas definiciones requieren declarar si se trabaja por componente, con eficiencia global o con distancias infinitas. Una red de mundo pequeño combina distancias que crecen lentamente con n y clustering mayor que un baseline comparable (Watts and Strogatz, 1998). La etiqueta exige las dos comparaciones; una distancia media baja por sí sola no basta.

2.8. Centralidades y medidas de importancia

Una centralidad ordena nodos según un proceso implícito. Las medidas siguientes fijan la notación; el capítulo 3 muestra cómo convertirlas en features y someter sus rankings a sensibilidad.

2.8.1. Centralidad de grado

El grado k_i cuenta vecinos. Puede representar oportunidades de contacto si cada arista ofrece una oportunidad comparable; no registra la posición de esos vecinos ni la intensidad de la relación (Rodrigues, 2018).

2.8.2. Centralidad de intermediación

La *centralidad de intermediación* $C_B(i)$ se define como:

$$C_B(i) = \sum_{s \neq i \neq t} \frac{\sigma_{st}(i)}{\sigma_{st}}, \tag{2.7}$$

Un nodo con alta intermediación participa en muchos caminos geodésicos. La interpretación como puente exige que el flujo use rutas mínimas y que los pares origen–destino reciban el peso supuesto por la fórmula. El algoritmo de Brandes evita enumerar todos los caminos, pero el cálculo exacto sigue siendo costoso en grafos grandes; el muestreo debe reportar su error (Rodrigues, 2018).

2.8.3. Centralidad eigenvectorial

La *centralidad eigenvectorial* asigna un valor alto a los nodos que están conectados a otros nodos importantes. Se define como el vector propio principal de la matriz de adyacencia: sea $\boldsymbol{v}$ un vector no nulo y λ un escalar tales que

$$A\,\boldsymbol{v} = \lambda\,\boldsymbol{v}, \tag{2.8}$$

con λ el mayor valor propio de A. La componente v_i crece cuando i se conecta con nodos que también reciben valores altos. En redes desconectadas o muy heterogéneas, el autovector puede concentrarse en un componente o en pocos hubs; esa localización limita su lectura como prestigio global (Rodrigues, 2018).

2.8.4. Centralidad de cercanía

Otra medida clásica es la *centralidad de cercanía*, definida como el inverso de la suma de distancias desde i a todos los demás nodos:

$$C_C(i) = \frac{n-1}{\sum_{j \neq i} d(i,j)}. \tag{2.9}$$

La expresión supone conectividad. En redes desconectadas debe restringirse el universo de pares o usar cercanía armónica; asignar una distancia finita arbitraria a nodos inalcanzables cambia el ranking. La métrica describe acceso geodésico, no velocidad real sin un modelo de flujo.

2.9. Laplaciano de grafos y operadores espectrales

2.9.1. Definición

Sea $D = \mathrm{diag}(k_1, \ldots, k_n)$ la matriz diagonal de grados. El *Laplaciano combinatorio* de un grafo no dirigido es

$$L = D - A. \tag{2.10}$$

Para cualquier vector $\boldsymbol{x} \in \mathbb{R}^n$ se cumple

$$\boldsymbol{x}^\top L \boldsymbol{x} = \frac{1}{2} \sum_{i,j} A_{ij}(x_i - x_j)^2 \geq 0, \tag{2.11}$$

por lo que L es semidefinido positivo. Además, $L\mathbf{1} = \mathbf{0}$: el valor propio cero siempre existe (Newman, 2010).

2.9.2. Interpretación física (difusión, suavizado)

La ecuación de difusión sobre el grafo,

$$\frac{d\boldsymbol{x}}{dt} = -L\boldsymbol{x}, \tag{2.12}$$

reduce diferencias entre nodos adyacentes. La solución $\boldsymbol{x}(t) = \exp(-tL)\boldsymbol{x}(0)$ descompone el estado inicial en modos espectrales: los asociados a valores propios grandes decaen con rapidez y los modos suaves, que varían poco entre vecinos, persisten más tiempo. Esta propiedad conecta el Laplaciano con regularización, clustering espectral y convoluciones sobre grafos.

2.9.3. Relación con conectividad y cortes

La multiplicidad del valor propio cero coincide con el número de componentes conexas. En un grafo conexo, el segundo valor propio más pequeño, $\lambda_2(L)$, se denomina *conectividad*

algebraica. Un valor pequeño se asocia con un cuello de botella: existe una partición que separa grupos mediante relativamente pocas aristas. El autovector correspondiente, conocido como vector de Fiedler, proporciona una relajación espectral del problema de corte.

2.9.4. Laplaciano normalizado

Cuando los grados son heterogéneos, se utilizan las formas

$$L_{\text{rw}} = I - D^{-1}A, \qquad L_{\text{sym}} = I - D^{-1/2}AD^{-1/2}, \tag{2.13}$$

para nodos de grado positivo. L_{rw} se vincula con el paseo aleatorio cuya matriz de transición es $P = D^{-1}A$; L_{sym} es simétrico y resulta conveniente para métodos espectrales. Normalizar cambia el problema: reduce la dominancia de nodos de alto grado, pero no elimina la necesidad de justificar qué nulo o proceso representa mejor la aplicación.

2.10. Conclusiones

La matriz de adyacencia conserva la topología; los pesos agregan intensidad; y la representación bipartita conserva tipos de nodo que una proyección puede ocultar. Clustering y distancia describen escalas distintas. Las centralidades y el espectro del Laplaciano formulan preguntas adicionales sobre posición, conectividad y difusión. La elección entre estas medidas debe seguir a la construcción de la red y al proceso que se desea analizar.

Capítulo 3

Centralidades como features: medición, sensibilidad y desigualdad

3.1. De una métrica a una variable defendible

Una centralidad es una hipótesis sobre cómo la posición de un nodo se relaciona con un proceso. El grado cuenta oportunidades locales; la cercanía supone acceso por caminos geodésicos; la intermediación asigna valor al tránsito entre pares; PageRank imagina un paseo con reinicios. Ordenar nodos sin declarar ese mecanismo produce un ranking, pero no una medida interpretable de influencia o poder (Freeman, 1978; Borgatti, 2005).

El capítulo anterior introdujo las fórmulas básicas. Aquí el problema cambia: convertirlas en variables reproducibles, comparables entre redes y útiles para segmentación o predicción. Una columna llamada `betweenness` no está definida hasta registrar el grafo, el tratamiento de pesos, los componentes, la normalización y la ventana temporal que la produjeron.

3.2. Elegir la familia de features según el proceso

Familia	**Proceso implícito**	**Fallo frecuente**
Grado y fuerza	contacto local o volumen de interacción	confundir actividad registrada con capacidad efectiva o prestigio
Cercanía armónica	acceso por rutas cortas hacia muchos nodos	mezclar componentes o tratar una arista intensa como una distancia larga
Intermediación	flujo por caminos mínimos entre pares	usarla cuando el proceso circula por rutas redundantes o paseos aleatorios
Eigenvector, Katz, PageRank	prestigio recursivo o acumulación a lo largo de caminatas	ignorar dirección, nodos colgantes, localización espectral o vector de reinicio
k-core	inserción en una región que resiste poda recursiva	interpretarlo como comunidad o como causalidad de la influencia

Cuadro 3.1: Centralidades como modelos de proceso. Una misma red admite varias nociones de importancia porque cada columna responde a una pregunta distinta.

PageRank, por ejemplo, satisface

$$\boldsymbol{c} = \alpha P^{\mathsf{T}} \boldsymbol{c} + (1 - \alpha)\boldsymbol{v}, \tag{3.1}$$

donde P incorpora una regla para nodos sin salidas y $\boldsymbol{v}$ define el reinicio. Alterar α o $\boldsymbol{v}$ cambia el estimando; no son detalles de implementación (Page et al., 1999). La claridad conceptual de las centralidades clásicas sigue siendo una referencia precisamente porque obliga a conectar fórmula y noción de importancia (Freeman, 1978).

3.3. Pesos, distancias y ventanas

El significado del peso determina la transformación. Si w_{ij} mide costo o tiempo, puede entrar directamente como longitud. Si mide intensidad, capacidad o frecuencia, usarlo como distancia invierte la interpretación: una relación más fuerte se vuelve un trayecto más largo. Dos transformaciones habituales son

$$\ell_{ij} = \frac{1}{w_{ij} + \varepsilon} \qquad \text{o} \qquad \ell_{ij} = -\log\left(\frac{w_{ij}}{w_{\text{máx}}}\right), \tag{3.2}$$

con supuestos diferentes sobre cómo cae la accesibilidad. La elección debe declararse y compararse con alternativas plausibles.

La ventana temporal también es parte de la feature. Sea $c_i(\Delta, \tau)$ la centralidad del nodo i calculada en una ventana de longitud Δ y con umbral de arista τ. Una conclusión estable no exige que el valor sea idéntico para todo (Δ, τ), pero sí que los cambios de ranking tengan una explicación. Redes de colaboración, comunicación o copresencia pueden perder conectividad bajo ventanas breves y fabricar caminos bajo ventanas extensas.

3.4. Construcción de un feature store por nodo

Un *feature store* no es una colección de columnas producidas una vez. Es una tabla versionada cuya llave combina nodo y tiempo de corte. Una fila mínima contiene

1. identificador estable y tiempo de cálculo;
2. grado de entrada y salida, fuerza y actividad observada;
3. componente, tamaño del componente y distancia a aislados;
4. centralidades con parámetros y normalización explícitos;
5. mesoestructura: comunidad, coreness y rol, cuando corresponda;
6. cobertura y banderas de calidad del nodo;
7. versión del constructor de red y de la definición de cada feature.

Para comparar redes de tamaños distintos puede usarse una normalización teórica, un percentil dentro de la red o una estandarización dentro del periodo. Estas operaciones no son equivalentes. El percentil conserva orden y sacrifica distancia; el puntaje estandarizado conserva desviaciones respecto de una media que puede ser poco representativa en distribuciones pesadas. En variables positivas muy sesgadas suele ser preferible registrar el valor original y una transformación $\log(1 + x)$.

3.5. Redundancia y estabilidad de rankings

Las centralidades pueden responder a mecanismos distintos y aun así producir rankings parecidos. La redundancia se mide en la red observada, no se decide por intuición. Para dos features c y d, la correlación de Spearman compara sus órdenes. Para los K primeros nodos puede usarse

$$S_K(c,d) = \frac{|\operatorname{Top}_K(c) \cap \operatorname{Top}_K(d)|}{|\operatorname{Top}_K(c) \cup \operatorname{Top}_K(d)|}. \tag{3.3}$$

Un ρ global alto puede coexistir con desacuerdo entre los nodos que reciben una intervención. El análisis debe reportar ambos niveles.

La estabilidad se evalúa perturbando las decisiones que razonablemente podrían haber sido otras: ventana, umbral, pesos, eliminación de aristas, resolución de comunidades y semilla algorítmica. Si $R_i^{(b)}$ es el rango de i en la réplica b, la distribución de $R_i^{(b)}$ comunica mejor la incertidumbre que un único ordenamiento. En redes incompletas, la perturbación debe aproximar el mecanismo de pérdida; borrar aristas uniformemente rara vez representa una plataforma o encuesta real.

3.6. Centralidad, poder e inequidad

Una distribución concentrada de centralidad describe posiciones desiguales dentro de la red construida. Se convierte en evidencia sobre poder solo cuando la arista transporta el recurso relevante y la métrica representa su circulación. Los vínculos débiles pueden conectar regiones sociales separadas (Granovetter, 1973); una alta intermediación puede entonces señalar acceso a información no redundante. Si el flujo no sigue caminos mínimos, esa lectura pierde fundamento.

Los estudios aplicados muestran la necesidad de esa correspondencia. La posición de academias de ballet se asocia con inserción profesional (Herrera-Guzmán et al., 2023); en redes de copresencia de repartidores, grado e intermediación se relacionan con ingresos (Pilatti et al., 2023); y en colicitación, distintas centralidades presentan asociaciones diferentes con ganancias por oferta (Sturm et al., 2025). Ninguno de estos resultados autoriza a tratar centralidad y éxito como sinónimos fuera del diseño que los produjo.

Cuando interesa concentración puede calcularse el Gini de una feature no negativa,

$$G(c) = \frac{\sum_i \sum_j |c_i - c_j|}{2N \sum_i c_i}. \tag{3.4}$$

El denominador exige $\sum_i c_i > 0$. Comparar $G(c)$ entre redes requiere normalizaciones, cobertura y unidades compatibles; de otro modo, un cambio de tamaño o densidad puede parecer un cambio sustantivo de desigualdad.

3.7. Features sin leakage

Toda feature relacional debe calcularse con el grafo disponible en el momento de la predicción. En un corte temporal t_0, el grado, la comunidad y el embedding de entrenamiento usan únicamente eventos con $t \le t_0$. En predicción de enlaces, la arista objetivo se retira antes de calcular vecinos comunes, Jaccard o message passing. Calcular primero el grafo completo y dividir después las filas transfiere información del futuro hacia el modelo.

Esta regla incluye transformaciones aparentemente inocuas: selección de umbral, normalización, imputación y elección de features. Cada una debe ajustarse dentro del conjunto de entrenamiento. El capítulo 11 formaliza los regímenes transductivo, inductivo y temporal.

3.8. Cierre

Un feature store de red debe permitir reconstruir cada columna y discutir qué proceso representa. Esa exigencia cambia el orden de trabajo: primero se define el mecanismo, luego el grafo y recién entonces la centralidad. La sensibilidad no es un apéndice; muestra cuánto del ranking pertenece al sistema y cuánto a las decisiones del analista.

Capítulo 4

Modelos generativos, nulos y baselines

4.1. Tres usos que no deben confundirse

Un modelo generativo propone una regla capaz de producir redes. Un modelo nulo elimina el mecanismo de interés y conserva restricciones que podrían explicar el patrón observado. Un baseline establece el mínimo de comparación para una tarea predictiva o descriptiva. Un mismo modelo puede cumplir más de una función, pero la inferencia depende de cuál se declare.

Erdős–Rényi (ER), Watts–Strogatz (WS) y Barabási–Albert (BA) son útiles porque aislan independencia, recableado y crecimiento preferencial. No forman una escalera de realismo. Cada uno responde una pregunta distinta y falla de una manera informativa (Newman, 2003; Barabási and Pósfai, 2016).

4.2. Erdős–Rényi: independencia de aristas

En $G(n,p)$, cada uno de los $\binom{n}{2}$ pares recibe una arista de forma independiente con probabilidad p. Para un grafo concreto con m aristas,

$$\Pr(G) = p^m(1-p)^{\binom{n}{2}-m}. \tag{4.1}$$

El grado es binomial,

$$\Pr(K=k) = \binom{n-1}{k} p^k (1-p)^{n-1-k}, \tag{4.2}$$

y se aproxima por Poisson cuando n es grande y p pequeño con $\langle k\rangle = (n-1)p$ fijo. El clustering esperado es p y la transición hacia un componente gigante ocurre alrededor de $\langle k\rangle = 1$.

Como baseline, ER pregunta cuánto patrón aparece solo por tamaño y densidad. Su homogeneidad de grados suele ser una mala descripción de redes empíricas; precisamente por eso, una desviación frente a ER no identifica por sí sola comunidad, homofilia ni crecimiento. Puede deberse únicamente a la heterogeneidad de grados.

4.3. Modelo de configuración: controlar el grado

El modelo de configuración fija una secuencia de grados y empareja aleatoriamente los *stubs*. En su forma idealizada puede producir autolazos y multiaristas; las implementaciones para grafos simples deben declarar si rechazan emparejamientos, usan recableado o muestrean de

una distribución condicionada. Para una secuencia $k_1, \ldots, k_n$, una aproximación frecuente es

$$\mathbb{E}_0[A_{ij}] \approx \frac{k_i k_j}{2m}. \tag{4.3}$$

Este control cambia la pregunta. Comparar modularidad o motivos con ER pregunta si exceden lo esperado por densidad; compararlos con configuración pregunta si exceden lo esperado por la secuencia de grados. El trabajo de Newman et al. (2001) desarrolla las consecuencias de distribuciones arbitrarias de grado y muestra por qué el primer momento no basta para caracterizar conectividad.

4.4. Watts–Strogatz: atajos sobre orden local

WS parte de un anillo regular de n nodos, cada uno conectado a sus vecinos próximos, y recablea aristas con probabilidad β. En $\beta = 0$ dominan la regularidad y el clustering; al aumentar β, pocos atajos reducen la longitud media antes de destruir completamente la estructura local (Watts and Strogatz, 1998).

El modelo sirve para estudiar el compromiso entre cierre local y accesibilidad global. No explica automáticamente el origen de grupos sociales: el anillo y el recableado ya imponen una geometría. Una comparación empírica debe calibrar n, número de aristas y, cuando sea pertinente, el grado inicial. Elegir β por semejanza visual con una figura no constituye estimación.

4.5. Barabási–Albert: crecimiento y ventaja acumulativa

En BA, cada nodo nuevo agrega m_0 aristas y elige un nodo existente i con probabilidad

$$\Pi_i(t) = \frac{k_i(t)}{\sum_j k_j(t)}. \tag{4.4}$$

La aproximación continua conduce a una cola $P(k) \propto k^{-3}$ bajo los supuestos específicos del modelo (Barabási and Albert, 1999). Observar una cola pesada no prueba attachment preferencial ni justifica llamar a la red «scale-free». Fitness, envejecimiento, heterogeneidad no observada y mezclas de poblaciones pueden producir patrones similares.

La atención cultural y científica ofrece un caso más exigente. Citaciones, patentes y productos culturales combinan acumulación con olvido en escalas temporales distintas (Candia et al., 2019b; Candia and Uzzi, 2021). Un mecanismo de crecimiento sin envejecimiento puede reproducir parte de la distribución final y fallar en la trayectoria que la generó.

4.6. Calibración y model checking

El modelo se calibra con estadísticas que correspondan a sus parámetros; se evalúa con estadísticas que no fueron forzadas durante el ajuste. Si ER se calibra fijando $\widehat{p} = 2m/[n(n-1)]$, la densidad ya no sirve como evidencia de ajuste. Deben examinarse grado, clustering, componentes, distancias, assortativity y, cuando exista tiempo, crecimiento y persistencia.

Sea $T(G)$ una estadística de diagnóstico y $G^{(1)}, \ldots, G^{(R)} \sim M(\widehat{\theta})$ redes simuladas. El contraste gráfico y numérico usa la distribución

$$\left\{T(G^{(1)}), \ldots, T(G^{(R)})\right\} \quad \text{frente a} \quad T(G_{\text{obs}}). \tag{4.5}$$

Un intervalo simulado que excluye $T(G_{\text{obs}})$ localiza una insuficiencia del modelo; no prueba por sí mismo una explicación alternativa. Debe reportarse el número de réplicas, la incertidumbre Monte Carlo y todas las estadísticas examinadas, no solo las que producen una diferencia llamativa.

4.7. Diseñar el nulo desde la pregunta

La aleatorización válida conserva las restricciones ajenas a la hipótesis y destruye el patrón que se desea contrastar (Gotelli, 2000). Algunos ejemplos:

- ER conserva aproximadamente tamaño y densidad.
- Configuración conserva la secuencia de grados.
- Un *degree-preserving rewiring* conserva grados y número de aristas.
- Un nulo bipartito conserva grados de actores y eventos.
- Una permutación temporal puede conservar actividad diaria y destruir orden entre contactos.
- Una permutación de etiquetas conserva el grafo y rompe la asociación atributo–red.

Cada conservación protege contra una explicación trivial y, al mismo tiempo, limita la pregunta. En colicitación, un nulo bipartito puede controlar cuántas licitaciones enfrenta cada firma y cuántos oferentes recibe cada proceso (Lyra et al., 2021; Sturm et al., 2025). Un nulo unipartito aplicado después de la proyección ya perdió esa información.

4.8. Protocolo reproducible de comparación

1. Definir G_{obs}, población, periodo y reglas de construcción.
2. Escribir la hipótesis en términos de una estadística T antes de simular.
3. Elegir las restricciones que el nulo debe conservar.
4. Estimar o fijar parámetros sin usar el diagnóstico final como criterio oculto.
5. Generar réplicas independientes y verificar que las restricciones se cumplan.
6. Comparar estadísticas preespecificadas y visualizar distribuciones completas.
7. Repetir bajo nulos alternativos que representen explicaciones plausibles.
8. Informar fallos de ajuste; son evidencia sobre el límite del modelo.

Los modelos simples ganan valor cuando fallan de forma localizada. Si configuración explica la distribución de motivos y no el clustering, el residuo apunta hacia cierre triádico u otra dependencia local. Si BA reproduce la cola de grados y falla en edades o comunidades, la red requiere mecanismos adicionales. La comparación disciplinada convierte una colección de simuladores en inferencia.

Capítulo 5

Mesoestructura: comunidades, núcleos y roles

5.1. La escala intermedia no es una partición única

Entre el nodo y la red completa aparecen regularidades que responden a preguntas distintas. Una comunidad agrupa nodos con conexión interna mayor que una referencia; un núcleo identifica inserción o densidad central; un rol reúne nodos con patrones de relación semejantes aunque no estén conectados entre sí. Aplicar un solo algoritmo y llamar «estructura» a su salida borra esas diferencias.

La mesoestructura tampoco es un atributo inmutable del grafo. Depende de pesos, dirección, resolución, tiempo, modelo nulo y objetivo. Dos particiones distintas pueden ser compatibles con el mismo sistema porque capturan escalas o mecanismos diferentes (Fortunato, 2010).

5.2. Modularidad y parámetro de resolución

Para una partición $\boldsymbol{g} = (g_1, \ldots, g_n)$ de una red no dirigida, la modularidad con resolución γ es

$$Q(\boldsymbol{g}; \gamma) = \frac{1}{2m} \sum_{i,j} \left(A_{ij} - \gamma \frac{k_i k_j}{2m} \right) \mathbf{1}\{g_i = g_j\}. \tag{5.1}$$

Con $\gamma = 1$ se obtiene la forma clásica basada en configuración (Newman, 2006). Valores mayores tienden a favorecer grupos más pequeños; valores menores, grupos más grandes. La resolución forma parte del resultado y debe reportarse.

Maximizar Q no demuestra que la partición sea verdadera. La modularidad tiene límite de resolución, presenta muchas soluciones cercanas al óptimo y puede asignar valores altos a estructuras difíciles de interpretar. Además, su nulo presupone que conservar grados es la comparación pertinente. En redes espaciales, temporales o bipartitas puede requerirse otra expectativa.

5.3. Louvain, Leiden y estabilidad algorítmica

Louvain alterna movimientos locales de nodos con agregación jerárquica y escala bien a redes grandes (Blondel et al., 2008). Su rapidez lo volvió un estándar operativo, pero una

puntuación alta no evita comunidades internamente mal conectadas. Leiden añade una fase de refinamiento y corrige ese fallo estructural, produciendo particiones con mejores garantías de conectividad bajo su criterio de optimización (Traag et al., 2019).

Ambos métodos son estocásticos. Un protocolo mínimo ejecuta R semillas para cada γ y conserva la partición, Q, número de comunidades, tamaño del grupo mayor y fracción de nodos que cambia de asignación. La semejanza entre dos particiones $\mathcal{P}$ y $\mathcal{Q}$ puede resumirse mediante la variación de información

$$\mathrm{VI}(\mathcal{P}, \mathcal{Q}) = H(\mathcal{P}) + H(\mathcal{Q}) - 2I(\mathcal{P}, \mathcal{Q}), \tag{5.2}$$

donde H es entropía e I información mutua. Un Q estable con VI alta indica que el objetivo admite soluciones estructuralmente distintas.

5.3.1. Barrido de resolución y consenso

La estabilidad relevante no se limita a repetir semillas. Deben variarse resolución, ponderación, umbral y ventana temporal. Una partición merece interpretación si persiste en una región de parámetros o si existe una razón sustantiva para elegir un punto particular. Cuando varias soluciones son equivalentes, una matriz de coasignación

$$C_{ij} = \frac{1}{R} \sum_{r=1}^{R} \mathbf{1}\{g_i^{(r)} = g_j^{(r)}\} \tag{5.3}$$

permite construir consenso sin fingir que una corrida representa toda la incertidumbre.

5.4. Descomposición k-core y core–periphery

El k-core es el subgrafo maximal en el que todos los nodos tienen grado interno al menos k. Se obtiene eliminando recursivamente nodos con grado menor que k; la *coreness* de un nodo es el mayor k para el cual permanece. Esta definición mide inserción en una región resistente a poda, no densidad global ni pertenencia comunitaria. En difusión, coreness puede superar al grado como predictor de alcance bajo ciertos procesos, pero esa ventaja no es universal (capítulo 7).

Una estructura core–periphery plantea otra geometría: un núcleo conectado entre sí y con la periferia, acompañado por nodos periféricos con pocos vínculos mutuos (Borgatti and Everett, 2000). Puede formalizarse comparando la matriz observada con un patrón ideal, mediante modelos de bloques o con versiones continuas de coreness. Una red puede tener k-cores anidados sin ajustarse bien a un modelo core–periphery y puede exhibir varios pares núcleo–periferia dentro de comunidades distintas.

El ajuste se compara con alternativas. La evidencia mínima incluye calidad respecto de un nulo, estabilidad ante perturbaciones y residuos por bloque. En compras públicas, por ejemplo, un núcleo persistente puede reflejar escala de proveedores, especialización o reglas institucionales. La estructura identifica una regularidad; no decide entre esas explicaciones.

5.5. Roles y equivalencias

Los roles agrupan nodos por la forma de sus conexiones. La equivalencia estructural exige vecindarios idénticos; la equivalencia regular permite que nodos diferentes se relacionen con clases semejantes; la equivalencia estocástica exige probabilidades de enlace similares hacia cada bloque. Esta última conecta roles con modelos de bloques estocásticos (Rossi and Ahmed, 2015).

Un nodo puente en dos comunidades alejadas puede compartir rol sin compartir vecinos. Por eso, clustering de embeddings estructurales y detección de comunidades no son operaciones intercambiables. Los primeros buscan semejanza de posición; la segunda, densidad o flujo interno.

5.6. Validación externa y límites de interpretación

Una partición se vuelve sustantiva cuando predice o organiza información que no entró en su construcción. En copresencia laboral, las comunidades pueden contrastarse con especialización espacial (Pilatti et al., 2023); en redes léxicas, con contenido y orientación política (Raveau et al., 2024). La validación externa debe reservarse de la selección de parámetros para evitar circularidad.

El reporte de mesoestructura debe incluir:

1. definición del grafo, pesos, dirección y ventana;
2. función objetivo, algoritmo, versión y parámetros;
3. número de semillas y distribución de calidad;
4. estabilidad entre semillas, resoluciones y perturbaciones;
5. comparación Louvain–Leiden u otro algoritmo pertinente;
6. modelo nulo y evidencia externa usada para interpretar;
7. nodos o grupos cuya asignación es incierta.

Una comunidad es una estimación dependiente del diseño, no una etiqueta natural escondida en la matriz. El análisis gana credibilidad cuando conserva la incertidumbre de la partición y muestra qué afirmaciones sobreviven a soluciones alternativas.

Capítulo 6

Inferencia estadística en redes complejas

6.1. El objeto inferencial

En datos tabulares, la unidad de observación suele coincidir con la unidad de análisis. En una red esa equivalencia se rompe. Dos díadas que comparten un nodo no son independientes; el grado de un actor depende de todas sus aristas y una centralidad global puede cambiar cuando se agrega una conexión lejos de su vecindario. Antes de calcular un error estándar o un valor p es necesario precisar qué se considera aleatorio: la existencia de las aristas, el conjunto de nodos observados, sus atributos, el proceso de muestreo o una combinación de estos elementos (Wasserman and Faust, 1994; Newman, 2010).

Sea $G_{\text{obs}} = (V, E)$ la red observada y $T(G)$ una estadística, por ejemplo el coeficiente de clustering, la modularidad o la correlación entre un atributo y el grado. Una pregunta inferencial bien definida compara $T(G_{\text{obs}})$ con su distribución bajo un modelo $\mathcal{M}$ que represente una hipótesis sustantiva. Sin ese modelo de referencia, afirmar que una red es "muy agrupada" o que una centralidad es "significativa" carece de escala de comparación.

Los estudios de redes educativas ofrecen diseños contrastantes: experimentos de campo, asignación aleatoria de grupos, datos longitudinales y estimaciones cuasiexperimentales (Pulgar et al., 2020; Candia et al., 2022; Ramírez et al., 2025). La estadística de red puede ser la misma en estos estudios, pero la fuente de variación cambia lo que puede inferirse.

6.2. Dependencia estructural y límites del paradigma i.i.d.

La matriz de adyacencia contiene dependencias por construcción. En un grafo no dirigido, $A_{ij} = A_{ji}$; además, las variables A_{ij} y A_{ik} comparten al nodo i. En redes sociales aparecen dependencias adicionales por reciprocidad, cierre triádico, homofilia y contextos compartidos. Tratar las $n(n-1)/2$ díadas como observaciones i.i.d. subestima la incertidumbre y puede convertir regularidades mecánicas de la red en evidencia aparente.

El problema no se resuelve "controlando por grado" de manera automática. El grado puede ser una covariable, una consecuencia del mecanismo de formación o parte del resultado que se desea explicar. Su función debe fijarse en el diseño. La dependencia también altera la validación: separar filas al azar no equivale a separar nodos, aristas, componentes o periodos, distinción que se retoma en el capítulo 11.

6.3. Modelos nulos como hipótesis estructurales

6.3.1. Erdős–Rényi

El modelo $G(n, p)$ fija n y hace independientes las aristas con probabilidad común p. Es una referencia para preguntar si una propiedad excede lo esperable dada solo la densidad. Su simplicidad es también su límite: cuando la red observada presenta grados muy heterogéneos, comparar contra $G(n, p)$ atribuye al fenómeno de interés diferencias que pueden provenir enteramente de la secuencia de grados (Newman, 2010; Barabási and Pósfai, 2016).

6.3.2. Modelo de configuración

El modelo de configuración conserva la secuencia de grados y aleatoriza el emparejamiento de extremos de aristas. En su aproximación canónica para una red no dirigida,

$$\mathbb{E}[A_{ij}] \approx \frac{k_i k_j}{2m}, \qquad m = |E|, \tag{6.1}$$

cuando los grados no son demasiado grandes respecto de m. Este control permite separar la organización mesoestructural de la heterogeneidad de grado. La modularidad adopta precisamente esta lógica al comparar las aristas internas observadas con las esperadas bajo un nulo que preserva grados (Newman, 2006; Fortunato, 2010).

6.3.3. Modelo de bloques estocásticos

Un *stochastic block model* (SBM) asigna cada nodo i a un bloque z_i y modela

$$A_{ij} \mid z_i = a, z_j = b \sim \text{Bernoulli}(\theta_{ab}). \tag{6.2}$$

La matriz $\boldsymbol{\Theta}$ expresa probabilidades de conexión entre bloques. El SBM sirve tanto como modelo generativo como hipótesis mesoestructural: permite preguntar si los datos sostienen comunidades, roles o una estructura núcleo–periferia. Los bloques no deben interpretarse como grupos sociales reales sin validación externa; son clases de equivalencia probabilística definidas por patrones de conexión.

6.4. Contrastes y cuantificación de incertidumbre

6.4.1. Pruebas por aleatorización

Una prueba válida genera redes $G^{(1)}, \ldots, G^{(B)}$ mediante transformaciones compatibles con la hipótesis nula y recalcula la misma estadística en cada réplica. Para una prueba unilateral, una estimación que evita valores cero es

$$\widehat{p} = \frac{1 + \sum_{b=1}^{B} \mathbb{I}\big[T(G^{(b)}) \geq T(G_{\text{obs}})\big]}{B + 1}. \tag{6.3}$$

La operación de aleatorización define el contraste. Permutar etiquetas prueba intercambiabilidad de atributos; recablear aristas preservando grados prueba una hipótesis estructural distinta. Mezclar ambas interpretaciones produce un valor p numéricamente correcto para una pregunta que nadie formuló.

6.4.2. Modularidad y centralidad

La modularidad maximizada siempre devuelve una partición, incluso en redes sin comunidades nítidas. Su valor debe compararse con redes nulas y someterse a análisis de estabilidad, porque el límite de resolución y la degeneración del paisaje de soluciones pueden producir particiones diferentes con puntuaciones similares (Fortunato, 2010).

Las centralidades tampoco son parámetros observados sin error. Una forma directa de evaluar su estabilidad consiste en perturbar la red según un modelo de error plausible y registrar la distribución del rango, no solo del valor. Si pequeños cambios de aristas invierten los primeros puestos, la conclusión defendible es que existe un conjunto de nodos estructuralmente prominentes, no un ganador inequívoco.

6.4.3. Bootstrap y simulación paramétrica

El bootstrap clásico de filas no conserva la dependencia relacional. En redes egocéntricas puede remuestrearse la unidad primaria de muestreo si el diseño lo permite; en redes completas suele ser preferible simular desde un modelo ajustado o usar perturbaciones calibradas al mecanismo de observación. La incertidumbre resultante es condicional al modelo. Por eso deben reportarse el procedimiento de generación, las restricciones preservadas y la sensibilidad a modelos alternativos.

6.5. Redes incompletas y sensibilidad estructural

Los enlaces ausentes no equivalen necesariamente a ceros. Una API puede truncar vecinos, un sensor puede fallar durante ciertos periodos y un cuestionario egocéntrico puede limitar el número de nominaciones. Cada mecanismo de ausencia deforma propiedades diferentes: el submuestreo de nodos altera caminos y componentes; la pérdida de aristas reduce clustering y puede cambiar la mesoestructura; la agregación temporal crea caminos que nunca existieron en el orden observado.

Un análisis profesional debe incluir, como mínimo, escenarios de sensibilidad. Sea δ una tasa plausible de error y $\mathcal{P}_\delta$ un mecanismo de perturbación. La curva

$$S_T(\delta) = \mathbb{E}_{G' \sim \mathcal{P}_\delta(G_{\text{obs}})}[T(G')] \tag{6.4}$$

muestra si la conclusión depende de una precisión de medición que los datos no pueden garantizar. El mecanismo de perturbación debe imitar el error sustantivo; eliminar aristas uniformemente al azar no representa un sistema de medición que falla por nodo o por tiempo.

6.6. Criterio de cierre inferencial

Una afirmación sobre redes queda respaldada cuando explicita: (i) la población y la ventana de observación; (ii) la regla que define nodos y aristas; (iii) el estimando o estadística; (iv) la fuente de aleatoriedad; (v) el modelo nulo o generativo; y (vi) la sensibilidad a datos incompletos y decisiones analíticas. La significancia estadística no sustituye estas definiciones. En redes, la mayor parte del rigor se decide antes de ejecutar la prueba.

Capítulo 7

Procesos sobre redes

7.1. Difusión y contagio en redes heterogéneas

7.1.1. Intuición: por qué la topología cambia la dinámica

Dos poblaciones con la misma tasa media de contacto pueden sostener epidemias distintas. En una población bien mezclada, cada individuo enfrenta el entorno promedio. En una red, los contactos se concentran: hubs acumulan oportunidades de recibir y transmitir, mientras otros nodos permanecen en regiones poco accesibles. La topología altera dos objetos:

- **Umbrales y persistencia:** la transición entre extinción y endemicidad puede depender de momentos altos de la distribución de grados, de modo que redes muy heterogéneas pueden reducir drásticamente (o anular, asintóticamente) el umbral epidémico.
- **Heterogeneidad de riesgo e impacto:** la probabilidad de infectarse y de infectar a otros es altamente desigual; una fracción pequeña de nodos puede explicar gran parte de la propagación.

Los modelos SIS y SIR permiten separar persistencia, tamaño final y velocidad. El campo medio heterogéneo y la formulación espectral conectan esas cantidades con grado y espectro (Pastor-Satorras et al., 2015; Barrat et al., 2008; Newman, 2010).

7.1.2. Modelos SIS y SIR en redes: definición microscópica

Sea $G = (V, E)$ un grafo no dirigido, simple, con $|V| = N$ nodos y matriz de adyacencia A. Denotemos por $X_i(t) \in \{0, 1\}$ el estado del nodo i en tiempo t (0 susceptible, 1 infectado).

SIS (Susceptible–Infectado–Susceptible). En tiempo continuo, un nodo susceptible i se infecta con tasa

$$\beta \sum_j A_{ij} X_j(t), \tag{7.1}$$

y un nodo infectado se recupera con tasa μ (volviendo a susceptible). Este proceso es Markoviano y posee un estado absorbente libre de infección ($X_i \equiv 0$) y, para ciertos parámetros, un régimen endémico estacionario (Pastor-Satorras et al., 2015; Van Mieghem et al., 2009).

SIR (Susceptible–Infectado–Recuperado). Aquí, la recuperación es absorbente: $I \to R$ con tasa μ y R no vuelve a infectarse. SIR describe brotes finitos y su tamaño final, y se conecta elegantemente con percolación y métodos de message passing (Newman, 2002; Karrer and Newman, 2010; Pastor-Satorras et al., 2015).

7.1.3. Campo medio heterogéneo y segundo momento del grado

En redes grandes, una aproximación estándar para SIS es el *campo medio heterogéneo* (HMF), que agrupa nodos por grado k y asume equivalencia estadística dentro de cada clase de grado (Pastor-Satorras et al., 2015; Barrat et al., 2008).

Sea $\rho_k(t)$ la fracción de nodos de grado k infectados en t. En redes *no correlacionadas* (sin assortatividad por grado), la probabilidad de que un vecino de un nodo cualquiera esté infectado se aproxima por

$$\Theta(t) \;=\; \sum_k \frac{kP(k)}{\langle k\rangle}\,\rho_k(t), \tag{7.2}$$

donde $\frac{kP(k)}{\langle k\rangle}$ es la distribución de grado «vista desde una arista». El balance de tasas SIS en HMF es entonces

$$\frac{d\rho_k}{dt} \;=\; -\mu\,\rho_k \;+\; \beta\,k\,(1-\rho_k)\,\Theta. \tag{7.3}$$

Linealización y umbral. Cerca del estado libre de infección, $\rho_k \ll 1$ y $(1-\rho_k) \approx 1$, de modo que

$$\frac{d\rho_k}{dt} \;\approx\; -\mu\,\rho_k + \beta\,k\,\Theta. \tag{7.4}$$

Buscando soluciones estacionarias no triviales, se obtiene que existe un umbral en el cociente β/μ dado por

$$\left(\frac{\beta}{\mu}\right)_c^{\mathrm{HMF}} \;=\; \frac{\langle k\rangle}{\langle k^2\rangle}. \tag{7.5}$$

Equivalentemente, un «número reproductivo efectivo» a nivel de red puede definirse como

$$R_* \;=\; \frac{\beta}{\mu}\,\frac{\langle k^2\rangle}{\langle k\rangle}, \tag{7.6}$$

y la condición $R_* > 1$ marca endemicidad en HMF (Pastor-Satorras et al., 2015).

Caso scale–free y desaparición del umbral (HMF). Si $P(k) \propto k^{-\gamma}$ con $2 < \gamma \leq 3$, entonces $\langle k^2\rangle$ diverge con N (bajo supuestos estándar de corte superior), lo cual lleva a $(\beta/\mu)_c^{\mathrm{HMF}} \to 0$ cuando $N \to \infty$ (Pastor-Satorras et al., 2015; Barrat et al., 2008). La presencia de hubs crea «reservorios» que sostienen la infección incluso para transmisiones muy débiles.

7.1.4. Formulación espectral: umbral como función del radio espectral

HMF enfatiza momentos de $P(k)$, pero ignora detalles de conectividad. Una visión complementaria proviene de aproximaciones tipo *quenched mean-field* / NIMFA, que trabajan directamente con la matriz de adyacencia (Pastor-Satorras et al., 2015; Van Mieghem et al., 2009).

Sea $p_i(t) = \mathbb{P}[X_i(t) = 1]$. Una ecuación de balance (con cierre de independencia) es

$$\frac{dp_i}{dt} \;=\; -\mu p_i \;+\; \beta\,(1-p_i)\sum_j A_{ij}p_j. \tag{7.7}$$

Linealizando alrededor de $p_i \equiv 0$ se obtiene

$$\frac{d\boldsymbol{p}}{dt} \;\approx\; (\beta A - \mu I)\,\boldsymbol{p}. \tag{7.8}$$

La estabilidad del estado libre de infección se determina por el mayor autovalor Λ_1 de A:

$$\beta_c^{\text{spec}} \;=\; \frac{\mu}{\Lambda_1}. \tag{7.9}$$

Este resultado hace explícito que la propagación está controlada por el *modo dominante* del grafo (autovector principal), típicamente localizado en hubs y su vecindario en redes muy heterogéneas (Pastor-Satorras et al., 2015; Van Mieghem et al., 2009).

Comentario conceptual. HMF y el umbral espectral coinciden en ciertos regímenes, pero pueden diferir cuando existen correlaciones, localización espectral o estructura modular fuerte. En práctica, (7.9) suele ser una buena guía operacional, pues computar Λ_1 es factible incluso para redes grandes usando métodos iterativos (Pastor-Satorras et al., 2015; Van Mieghem et al., 2009).

7.1.5. Más allá del caso ideal: correlaciones, modularidad y redes temporales

En redes reales, tres extensiones son particularmente relevantes:

Correlaciones de grado (assortatividad). Si nodos de alto grado se conectan preferentemente con alto grado (assortative mixing), se modifica el umbral y la prevalencia; en general, el análisis requiere matrices de mezcla por grado o enfoques espectrales más finos (Newman, 2010; Pastor-Satorras et al., 2015).

Modularidad y cuellos de botella. En redes comunitarias, la propagación puede ser rápida dentro de comunidades pero lenta entre ellas; esto induce *dos escalas* de crecimiento y sugiere que ciertos nodos «puente» controlan la transmisión inter-comunidad.

Redes temporales y de contacto. Cuando las aristas aparecen/desaparecen en el tiempo, el orden temporal de contactos importa (caminos temporales). El umbral y la velocidad de difusión pueden cambiar drásticamente respecto a la red agregada.

Estas extensiones motivan modelos y métodos más avanzados (percolación dependiente del tiempo, aproximaciones de pares, message passing dinámico), pero los principios base siguen siendo: *heterogeneidad + estructura* reconfiguran umbrales, velocidades y tamaños finales (Pastor-Satorras et al., 2015; Barrat et al., 2008).

7.2. Influencia de la centralidad en la difusión

7.2.1. La importancia depende del proceso

Un nodo puede ser «importante» por múltiples razones: tener muchos contactos (grado), conectar comunidades (intermediación), estar cerca de todos (cercanía), o estar conectado a otros importantes (eigenvector/PageRank). Pero el mejor predictor de influencia depende del mecanismo de difusión (contagio simple vs complejo, presencia de modularidad, redundancia de caminos, etc.). Por eso, no existe una centralidad universal (Rodrigues, 2018; Borgatti, 2005).

7.2.2. Influencia como problema de intervención: inmunización e influencia máxima

En epidemiología de redes, una pregunta operativa es: *¿qué nodos conviene inmunizar (o bloquear) para minimizar la propagación?* En difusión de información: *¿qué nodos conviene activar como «semillas» para maximizar alcance?*

Inmunización dirigida. En redes heterogéneas, inmunizar al azar es ineficiente: la enfermedad «sobrevive» en hubs. Estrategias dirigidas (vacunar hubs) reducen fuertemente la prevalencia y pueden restaurar un umbral efectivo (Pastor-Satorras and Vespignani, 2002; Cohen et al., 2003).

Maximización de influencia. En modelos de difusión monotónica (p. ej., independent cascade o linear threshold), seleccionar un conjunto de semillas S para maximizar el alcance esperado es un problema combinatorio. Un resultado clásico es que para funciones de alcance submodulares, un algoritmo voraz logra una aproximación $(1 - 1/e)$ (Kempe et al., 2015).

7.2.3. Centralidades para contagio: grado vs. coreness (k-core)

Un hallazgo importante es que el grado no siempre identifica a los mejores propagadores. Kitsak et al. muestran que, en diversos grafos, nodos ubicados en el *núcleo* (alto *k-shell index* o *coreness*) pueden ser más influyentes que hubs periféricos: la razón es que el núcleo está densamente interconectado y sostiene cascadas de forma robusta (Kitsak et al., 2010).

Formalmente, la descomposición k-core elimina iterativamente nodos con grado menor que k; el mayor k para el cual un nodo permanece define su *coreness*. En difusión, el núcleo suele coincidir con regiones donde existen múltiples caminos redundantes, reduciendo cuellos de botella y aumentando el tamaño del brote.

7.2.4. Centralidad como modelo de flujo: cuándo sirve betweenness

Si el proceso efectivamente viaja por caminos geodésicos (o cuasi-geodésicos), la intermediación puede capturar «control» de flujo. Sin embargo, si la difusión se parece a un paseo aleatorio o contagio con múltiples rutas, betweenness puede sobrevalorar puentes que no son realmente críticos. Borgatti formaliza esta idea distinguiendo procesos por *transferencia* (walk-like) versus *serial* (path-like), lo cual guía qué centralidad es conceptualmente coherente (Borgatti, 2005).

7.3. Redes con estructura de mundo pequeño

7.3.1. Intuición: atajos reducen tiempos característicos

La estructura small-world enfatiza un trade-off topológico: redes regulares tienen alto clustering pero caminos largos; redes aleatorias tienen caminos cortos pero clustering bajo. El recableado de Watts–Strogatz introduce pocos «atajos» que colapsan las distancias manteniendo clustering alto (Watts and Strogatz, 1998; Newman, 2000).

Desde la perspectiva de procesos, reducir distancias reduce *tiempos de mezcla* y acelera difusión: si el diámetro efectivo pasa de orden N a orden $\log N$, entonces el número de «saltos» necesarios para alcanzar una fracción macroscópica de la red se reduce dramáticamente.

7.3.2. Watts–Strogatz y variantes analíticas

El modelo WS parte de un anillo regular donde cada nodo conecta con z vecinos y recablea aristas con probabilidad p (Watts and Strogatz, 1998). En la variante Newman–Watts se agregan enlaces en vez de reemplazarlos, lo que facilita el análisis de distancias (Newman, 2000). Una fracción pequeña de atajos puede reducir con rapidez la distancia media, aunque su efecto dinámico depende del proceso y de la ubicación de esos atajos.

7.3.3. Redes temporales vs redes agregadas

Una red temporal registra eventos (i, j, t) o intervalos $(i, j, t, \Delta t)$. La red agregada reemplaza esos eventos por una arista si existió al menos un contacto durante la ventana. Esta operación conserva volumen, según el peso elegido, pero pierde orden, concurrencia y duración. Dos secuencias con la misma matriz agregada pueden producir alcances y tiempos de contagio diferentes.

7.3.4. Caminos temporales

Un camino temporal de i a j es una secuencia de aristas con tiempos no decrecientes. La existencia de un camino en la red agregada es necesaria, pero no suficiente, para que el proceso pueda recorrerlo. Si el contacto $b \to c$ ocurre antes que $a \to b$, la ruta $a \to b \to c$ aparece en el grafo agregado aunque no sea causalmente transitable en esa ventana.

7.3.5. Consecuencias prácticas (orden importa)

La resolución temporal debe compararse con la escala del proceso. Ventanas demasiado largas fabrican simultaneidad; ventanas demasiado cortas fragmentan contactos que el proceso sí podría utilizar. Un análisis robusto reporta resultados para varias ventanas, conserva la flecha del tiempo en validación y compara la dinámica temporal con la predicción de la red agregada.

No toda dinámica relacional es contagio. La atención colectiva, por ejemplo, combina acumulación y olvido en escalas temporales distintas (Candia et al., 2019b; Candia and Uzzi, 2021; Candia, 2025). Del mismo modo, redes de colaboración observadas en olas sucesivas permiten estudiar persistencia y cambio de vínculos sin asumir que una arista transmite automáticamente un estado (Pulgar et al., 2022).

7.4. Qué puede sostener una conclusión sobre difusión

Para SIS, HMF relaciona el umbral con $\langle k\rangle/\langle k^2\rangle$; el enfoque espectral lo aproxima mediante $1/\Lambda_1$. Coinciden bajo ciertos regímenes y divergen con correlaciones, localización espectral o modularidad (Pastor-Satorras et al., 2015; Van Mieghem et al., 2009). Ninguna fórmula reemplaza la simulación calibrada cuando la red es temporal, dirigida o incompleta.

La intervención debe representar el proceso que intenta frenar. Coreness puede superar al grado en algunos escenarios de propagación, mientras la intermediación resulta adecuada solo si el flujo usa rutas cercanas a caminos mínimos (Kitsak et al., 2010; Pastor-Satorras and Vespignani, 2002; Cohen et al., 2003). La comparación debe incluir selección aleatoria y mantener el mismo presupuesto de nodos.

Redes temporales, contagios complejos y efectos causales exigen información adicional: orden de contactos, reglas de refuerzo y mapas de exposición. La red agregada indica quién pudo encontrarse. No demuestra quién transmitió ni qué habría ocurrido bajo otra intervención.

Capítulo 8

Causalidad, interferencia y efectos de red

8.1. Por qué una red cambia la pregunta causal

En el marco clásico de resultados potenciales, el resultado de una unidad depende de su propio tratamiento. En una red, el tratamiento asignado a los vecinos también puede afectarla. Una campaña informativa, una vacuna o una tecnología adoptada por un actor modifica oportunidades de exposición para otros actores. Esta *interferencia* no es un detalle del estimador: altera el estimando.

Sea $\boldsymbol{z} = (z_1, \ldots, z_n)$ el vector de asignaciones y $Y_i(\boldsymbol{z})$ el resultado potencial del nodo i. Sin restricciones existirían 2^n resultados potenciales por nodo en un tratamiento binario, una cantidad imposible de identificar con una sola red. El análisis requiere una representación reducida de la exposición.

8.2. Mapas de exposición

Un mapa de exposición resume las asignaciones relevantes para cada nodo:

$$e_i = f_i(\boldsymbol{z}, G). \tag{8.1}$$

Una opción simple para una red ponderada es la fracción tratada del vecindario,

$$e_i(\boldsymbol{z}, G) = \frac{\sum_j A_{ij} z_j}{\sum_j A_{ij}}, \tag{8.2}$$

definida para nodos con fuerza positiva. Esta elección supone que el efecto depende de la cantidad de exposición y no de la identidad de los vecinos, del orden temporal ni de caminos más largos. Un mapa alternativo puede distinguir al menos un vecino tratado, exposición ponderada, distancia al tratamiento o secuencias temporales. La topología por sí sola no elige entre estas posibilidades; el mecanismo sustantivo debe hacerlo.

Bajo la reducción $Y_i(z_i, e_i)$ pueden definirse dos contrastes. El efecto directo a una exposición fija e es

$$\tau_{\text{dir}}(e) = \mathbb{E}[Y_i(1, e) - Y_i(0, e)]\,, \tag{8.3}$$

mientras que un efecto indirecto o *spillover*, manteniendo el tratamiento propio, es

$$\tau_{\text{spill}}(z; e, e') = \mathbb{E}\big[Y_i(z, e) - Y_i(z, e')\big] \,. \tag{8.4}$$

Estas expresiones no identifican un efecto por sí mismas. Solo hacen explícito qué comparación se desea estimar.

8.3. Diseños de intervención

8.3.1. Aleatorización individual y saturación

La asignación individual permite variación dentro de vecindarios, pero genera exposiciones correlacionadas. Un diseño en dos etapas puede asignar primero una saturación de tratamiento a grupos y luego seleccionar individuos dentro de cada grupo. Así se comparan unidades con tratamiento propio similar pero diferente intensidad de tratamiento en su entorno.

8.3.2. Aleatorización por conglomerados

Asignar comunidades completas reduce contaminación entre tratamiento y control cuando la interferencia se concentra dentro de los grupos. La protección es parcial: aristas entre comunidades mantienen canales de exposición. La partición debe justificarse antes de mirar los resultados y la inferencia debe respetar la unidad de asignación.

En contextos educativos, la asignación de estudiantes a grupos aleatorios o autoseleccionados permite estudiar cómo la regla de formación modifica estabilidad, amistad y cooperación (Ramírez et al., 2025; Pulgar et al., 2025). El tratamiento es la regla de agrupación; las centralidades posteriores son resultados o mediadores, no covariables pretratamiento. Un manuscrito en preparación estudia, además, la amistad como moduladora de la expresión de jerarquía en la cooperación escolar (Oyarzún et al., 2026). Se incluye como *draft* y como ejemplo de una hipótesis relacional; no como evidencia publicada.

8.3.3. Selección de semillas

Cuando el tratamiento se entrega a un subconjunto de nodos para maximizar alcance, el problema combina inferencia y optimización. Los resultados dependen del modelo de difusión; una regla basada en grado, k-core o maximización de influencia codifica mecanismos distintos (Kitsak et al., 2010; Kempe et al., 2015). Evaluar una estrategia en los mismos datos usados para elegir semillas confunde selección con efecto.

8.4. Por qué una red observacional no identifica influencia

La similitud entre vecinos admite varias explicaciones. Puede surgir porque un actor influye en otro, porque personas similares forman enlaces o porque ambas responden a un contexto compartido. La homofilia está documentada en numerosos dominios sociales (McPherson et al., 2001); por tanto, una correlación entre Y_i y el promedio de Y_j entre vecinos no separa contagio de selección.

La red también puede ser endógena. Si el tratamiento cambia los enlaces, analizar solo el grafo posterior condiciona en una variable afectada por la intervención. Si la red se mide

con una plataforma o sensor, cobertura y actividad determinan quién aparece conectado. Los problemas de representatividad y validez de datos digitales se trasladan directamente a la identificación causal (Tufekci, 2014).

8.5. Estimación y diagnóstico

Un análisis debe calcular las probabilidades de exposición inducidas por el diseño. Los nodos de alto y bajo grado pueden tener probabilidades muy distintas de quedar expuestos; si alguna categoría de exposición es casi imposible, falla la positividad y el contraste se apoya en extrapolación. También deben examinarse:

- el balance de covariables por tratamiento y exposición;
- la sensibilidad a mapas de exposición alternativos;
- el solapamiento entre comunidades y canales de interferencia;
- la estabilidad frente a aristas o nodos no observados;
- la correspondencia temporal entre asignación, exposición y resultado.

En estudios observacionales, ajustar un modelo predictivo más flexible no reemplaza un diseño de identificación. El grafo puede mejorar la predicción y, al mismo tiempo, dejar intacto el sesgo causal.

Un manuscrito en preparación sobre preferencias universitarias combina distancias en una red de programas con discontinuidades de admisión (Davyt-Colo et al., 2026). Se cita aquí como *draft*: ilustra la separación entre una medida relacional pretratamiento y una fuente cuasiexperimental de asignación, no como evidencia publicada.

8.6. Alcance de las conclusiones

El lenguaje debe seguir al diseño. Una red transversal sustenta asociaciones estructurales; una secuencia temporal puede ordenar eventos, pero no elimina confusión; una intervención aleatoria permite efectos causales dentro de las exposiciones y la población que el diseño realmente cubre. Declarar el mapa de exposición, la unidad de asignación y los canales de interferencia es parte del resultado, no material suplementario.

Capítulo 9

Redes multicapa y multiplex

9.1. Cuándo una capa no basta

Una red agregada combina relaciones que pueden obedecer a mecanismos distintos. Dos personas pueden estar conectadas por colaboración, amistad y comunicación digital; dos ciudades, por rutas aéreas y ferroviarias. Sumar esas aristas destruye el tipo de relación y puede crear caminos que ningún proceso puede recorrer. Una representación multicapa conserva esa información cuando el proceso de interés distingue canales.

Sea $\mathcal{L} = \{1, \dots, L\}$ el conjunto de capas. Los objetos elementales son pares nodo–capa (i, α), y el conjunto observado puede ser un subconjunto $V_M \subseteq V \times \mathcal{L}$. Esta definición admite que un nodo no exista en todas las capas. Una red *multiplex* es el caso en que las capas describen tipos de enlace entre un conjunto comparable de nodos; una red temporal puede verse como capas ordenadas, pero el orden impone restricciones que una multiplex genérica no tiene.

9.2. Representación algebraica

9.2.1. Matriz supra-adyacente

La conectividad entre (i, α) y (j, β) se codifica en $A_{ij}^{\alpha\beta}$. Al ordenar todos los pares nodo–capa se obtiene la matriz supra-adyacente

$$\mathcal{A} = \begin{pmatrix} A^{11} & C^{12} & \cdots & C^{1L} \\ C^{21} & A^{22} & \cdots & C^{2L} \\ \vdots & \vdots & \ddots & \vdots \\ C^{L1} & C^{L2} & \cdots & A^{LL} \end{pmatrix}, \tag{9.1}$$

donde $A^{\alpha\alpha}$ contiene aristas dentro de la capa α y $C^{\alpha\beta}$ contiene acoplamientos entre capas. En una multiplex con identidad compartida es habitual conectar (i, α) con (i, β) mediante un peso $\omega_{\alpha\beta}$. Ese peso no es un parámetro decorativo: determina cuánto puede transferirse un proceso entre canales.

La fuerza supra-estructural es $s_{i\alpha} = \sum_{j,\beta} \mathcal{A}_{i\alpha,j\beta}$ y el Laplaciano

$$\mathcal{L} = \mathcal{D} - \mathcal{A}, \qquad \mathcal{D}_{i\alpha,i\alpha} = s_{i\alpha}. \tag{9.2}$$

Esta construcción extiende difusión, cortes y métodos espectrales al espacio de pares

nodo–capa. También eleva la dimensión de n a aproximadamente nL, con consecuencias computacionales y estadísticas.

9.2.2. Comunidades multicapa

La modularidad multicapa incorpora un nulo dentro de cada capa y acoplamientos entre réplicas de un nodo. El marco de Mucha et al. (2010) permite detectar comunidades que cambian entre capas o periodos. Un acoplamiento muy alto fuerza persistencia; uno muy bajo analiza las capas casi por separado. Por ello, una partición no debe reportarse sin el valor del acoplamiento y una curva de sensibilidad.

9.3. Procesos dinámicos en múltiples capas

9.3.1. Difusión acoplada

Para un estado $\boldsymbol{x}$ definido sobre pares nodo–capa, la difusión lineal satisface

$$\frac{d\boldsymbol{x}}{dt} = -\mathcal{L}\boldsymbol{x}. \tag{9.3}$$

Los autovalores de $\mathcal{L}$ controlan escalas de relajación. Cuando el acoplamiento entre capas es débil, cada capa conserva dinámicas parcialmente separadas; cuando es fuerte, las réplicas de un nodo tienden a comportarse como una unidad. La agregación es razonable solo en un régimen donde esa aproximación reproduce la escala del proceso estudiado.

9.3.2. Contagio

En una aproximación espectral de un proceso SIS homogéneo sobre la supra-red, el umbral se relaciona con el mayor autovalor de $\mathcal{A}$,

$$\lambda_c \approx \frac{\mu}{\Lambda_{\text{máx}}(\mathcal{A})}, \tag{9.4}$$

donde λ y μ son tasas de transmisión y recuperación. La expresión depende de la aproximación y no sustituye un análisis del proceso microscópico; muestra, sin embargo, que una capa poco densa puede sostener contagio al acoplarse con otra de gran radio espectral (Pastor-Satorras et al., 2015).

9.3.3. Redes temporales

En redes temporales, una arista solo puede utilizarse después de aparecer. La matriz agregada puede contener un camino $i \to j \to k$ aunque la arista $j \to k$ ocurra antes que $i \to j$. Los modelos de grafos temporales conservan eventos y estados en orden; las arquitecturas de aprendizaje temporal también deben impedir que información futura ingrese en el entrenamiento (Rossi et al., 2021).

Las redes escolares observadas en modalidades remota, híbrida y presencial muestran una razón sustantiva para conservar contexto y tiempo: conectividad, amistad, colaboración y prestigio académico no son capas intercambiables y pueden cambiar entre periodos (Pulgar et al., 2022, 2023). Agregarlas en una sola arista impediría distinguir qué relación se asocia con cada resultado.

9.4. Decisiones de modelado y validación

Separar capas requiere una regla observacional, no solo una conveniencia gráfica. Debe documentarse:

- qué significa una arista dentro de cada capa y si sus pesos son comparables;
- qué representa el acoplamiento entre capas y cómo se estima;
- qué nodos existen, están ausentes o no fueron observados en cada capa;
- si el orden temporal restringe los caminos posibles;
- qué conclusión cambia respecto de analizar capas separadas o una red agregada.

La comparación con esos dos baselines —capas independientes y agregación— es esencial. Si el modelo multicapa no mejora descripción, predicción o identificación de un mecanismo, su complejidad adicional no está justificada.

9.5. Identificabilidad, cobertura y escala

El primer desafío es la identificabilidad: estructura intra-capa y acoplamiento pueden producir patrones similares. El segundo es la cobertura desigual, porque confundir ausencia de un nodo con ausencia de actividad sesga comparaciones. El tercero es la escalabilidad de operadores de tamaño nL. El cuarto es la interpretabilidad: una centralidad supra-espectral resume posición y acoplamiento, pero no explica qué canal genera el valor. En aprendizaje automático, los grafos heterogéneos ofrecen arquitecturas específicas para tipos de nodos y relaciones, aunque la ganancia predictiva debe separarse de una interpretación sustantiva de las capas (Shi et al., 2020).

Capítulo 10

Aprendizaje en redes

10.1. Representaciones y tareas en grafos

10.1.1. Intuición: ¿por qué aprender sobre grafos?

En una imagen, la vecindad de un píxel está fijada por la cuadrícula. En un grafo, cada nodo puede tener un número distinto de vecinos y su enumeración no posee significado. La arquitectura debe respetar esa simetría y decidir qué información viaja por aristas que pueden representar homofilia, interacción o dependencia (Hamilton, 2020).

Los principales problemas a abordar incluyen:

- **Clasificación de nodos:** predecir la etiqueta de un nodo (por ejemplo, el tipo de usuario en una red social) dado un pequeño subconjunto de nodos etiquetados.
- **Predicción de enlaces:** estimar la probabilidad de que exista (o se forme) una arista entre dos nodos, útil en sistemas de recomendación y detección de anomalías.
- **Detección de comunidades:** identificar grupos de nodos densamente interconectados o con roles similares; estas tareas pueden resolverse mediante técnicas de clustering sobre representaciones aprendidas.
- **Clasificación de grafos:** cuando los objetos de interés son grafos completos (p. ej. moléculas), se busca asignar una etiqueta al grafo entero, lo que requiere mecanismos de *pooling* o *lectura* global.

10.1.2. Fundamentos matemáticos de las representaciones

Sea $G = (V, E)$ un grafo y $X \in \mathbb{R}^{|V| \times d_0}$ su matriz de atributos. Un codificador nodal produce $\boldsymbol{h}_i = f_\theta(i; G, X) \in \mathbb{R}^d$; un codificador de grafos produce $\boldsymbol{h}_G = f_\theta(G, X)$. Las representaciones se ajustan mediante objetivos supervisados, auto-supervisados o generativos. No garantizan por sí mismas capturar "semántica": preservan las regularidades favorecidas por la arquitectura, el muestreo y la función de pérdida (Hamilton, 2020).

10.2. Embeddings basados en paseos aleatorios

10.2.1. Intuición: analogía entre grafos y lenguaje

DeepWalk trata nodos como palabras y paseos aleatorios como oraciones (Perozzi et al., 2014). Dos nodos reciben vectores próximos cuando aparecen en contextos de paseo semejantes. Esa proximidad puede reflejar vecindad, comunidad o patrones de retorno; no garantiza homofilia semántica fuera de la red.

10.2.2. Formulación matemática: DeepWalk y skip-gram

DeepWalk genera una colección de paseos $w_{1:t}^{(r)} = (v_{i_1}, v_{i_2}, \ldots, v_{i_t})$ mediante un proceso de Markov sobre el grafo:

$$\Pr[v_{i_{k+1}} = u \mid v_{i_k} = v] = \begin{cases} \frac{1}{\deg(v)}, & \text{si } (v,u) \in E, \\ 0, & \text{en otro caso.} \end{cases} \tag{10.1}$$

Para cada paseo, se define un contexto de tamaño C alrededor de cada paso v_{i_k} y se maximiza la probabilidad de observar los nodos del contexto dado el nodo actual mediante un modelo *skip-gram*:

$$\mathcal{L} = \sum_{w_{1:t}^{(r)}} \sum_{k=1}^{t} \sum_{\substack{-C \le \ell \le C \\ \ell \neq 0 \\ 1 \le k+\ell \le t}} \log \Pr(v_{i_{k+\ell}} \mid v_{i_k}), \tag{10.2}$$

donde $\Pr(v_j \mid v_i) \propto \exp(\boldsymbol{z}_i^\top \boldsymbol{z}'_j)$. En la práctica se emplean vectores de centro y contexto distintos y se aproxima el objetivo mediante *negative sampling*. El resultado depende de la longitud de los paseos, la ventana y la distribución de negativos (Perozzi et al., 2014).

Generalizaciones: node2vec y variantes. *node2vec* (Grover and Leskovec, 2016) introduce dos parámetros (p, q) que controlan la tendencia de los paseos a regresar al nodo anterior (sesgo de profundidad) o explorar nuevos vecindarios (sesgo de amplitud). Ajustando p, q, se pueden aprender embeddings que reflejen homofilia (trayectorias que permanecen cerca del nodo) o equivalencia estructural (trayectorias que saltan a nodos con rol similar). Otras extensiones, como LINE (Tang et al., 2015), HOPE, o métodos heterogéneos, abordan grafos dirigidos, con atributos o múltiples tipos de nodos.

10.3. Redes neuronales de grafos y message passing

10.3.1. Intuición: operadores locales y acoplamiento a la estructura

Una GNN aplica la misma regla local en toda la red: combina el estado de un nodo con mensajes de sus vecinos (Kipf and Welling, 2017; Hamilton et al., 2017). Después de ℓ capas, la representación puede depender de nodos a distancia ℓ, salvo muestreo o atajos arquitectónicos. La agregación debe ser invariante al orden de los vecinos; suma, media, máximo y atención implementan supuestos distintos sobre el multiconjunto recibido.

10.3.2. Formulación general de message passing

Considere un nodo v_i con embedding $h_i^{(l)}$ en la capa l. El esquema de message passing define (Hamilton et al., 2017; Veličković et al., 2018):

$$m_i^{(l+1)} = \mathrm{AGG}\Big(\big\{\phi(h_i^{(l)}, h_j^{(l)}, e_{ij}) : j \in \mathcal{N}(i)\big\}\Big), \tag{10.3}$$

$$h_i^{(l+1)} = \psi\big(h_i^{(l)}, m_i^{(l+1)}\big), \tag{10.4}$$

donde $\mathcal{N}(i)$ es el vecindario, e_{ij} representa atributos de la arista, ϕ es una función de mensaje y ψ actualiza el estado. El agregador debe ser invariante a permutaciones del multiconjunto de vecinos; suma, media, máximo y atención normalizada son construcciones habituales.

Ejemplo: Graph Convolutional Networks (GCN). Kipf y Welling (Kipf and Welling, 2017) propusieron una versión simplificada del message passing en el dominio espectral, que se puede escribir en forma matricial:

$$H^{(l+1)} = \sigma\big(\widetilde{D}^{-1/2}\widetilde{A}\widetilde{D}^{-1/2}H^{(l)}W^{(l)}\big), \tag{10.5}$$

donde $\widetilde{A} = A + I$ agrega lazos propios, $\widetilde{D}$ es la matriz diagonal de grados de $\widetilde{A}$, $H^{(l)}$ es la matriz de embeddings en la capa l y $W^{(l)}$ es una matriz de pesos. Esta capa lineal combina los atributos de un nodo con la media (normalizada) de sus vecinos.

Ejemplo: GraphSAGE. Hamilton et al. (Hamilton et al., 2017) generalizaron el concepto con agregadores paramétricos (media, LSTM, max pooling). Para cada nodo i se toma un subconjunto de vecinos $\mathcal{N}_S(i)$ y se define:

$$h_i^{(l+1)} = \sigma\Big(W^{(l)}\Big[h_i^{(l)} \,\|\, \mathrm{AGG}\big(\{h_j^{(l)} : j \in \mathcal{N}_S(i)\}\big)\Big]\Big), \tag{10.6}$$

donde $\|$ denota concatenación. GraphSAGE opera de forma *inductiva*: puede generalizar a nodos no vistos durante el entrenamiento, pues el agregador no depende del tamaño de G.

Ejemplo: Graph Attention Networks (GAT). Velickovic et al. (Veličković et al., 2018) introdujeron atención a nivel de aristas. Para cada vecino j se calcula un coeficiente de atención

$$\alpha_{ij} = \frac{\exp\big(\mathrm{LeakyReLU}(a^\top[Wh_i^{(l)} \,\|\, Wh_j^{(l)}])\big)}{\sum_{k\in\mathcal{N}(i)}\exp\big(\mathrm{LeakyReLU}(a^\top[Wh_i^{(l)} \,\|\, Wh_k^{(l)}])\big)}, \tag{10.7}$$

y luego

$$h_i^{(l+1)} = \sigma\Big(\sum_{j\in\mathcal{N}(i)} \alpha_{ij}\, Wh_j^{(l)}\Big). \tag{10.8}$$

La atención permite que la red aprenda a ponderar la importancia de cada vecino, lo que puede ser ventajoso cuando el grafo contiene ruidos o aristas irrelevantes.

10.3.3. Consideraciones avanzadas

La literatura reciente aborda retos como:

- **Heterofilia:** vecinos con etiquetas o atributos distintos pueden volver perjudicial el suavizado local; se requieren operadores que separen canales o exploten patrones de mayor orden (Bo et al., 2021).
- **Grafos dinámicos o temporales:** el tiempo debe entrar en la estructura y en el estado sin permitir información futura (Rossi et al., 2021).
- **Grafos heterogéneos:** distintos tipos de nodos y aristas requieren transformaciones y reglas de agregación específicas por relación (Shi et al., 2020).

Dos manuscritos en preparación muestran usos distintos de embeddings y se citan explícitamente como *drafts*. Uno representa participantes y propuestas a partir de elecciones de política (Fuentes-Jofre et al., 2026); el otro compara relatedness local con representaciones de orden superior para diversificación económica (Sturm et al., 2026). Ambos refuerzan un criterio metodológico: la geometría aprendida debe validarse contra variables externas y baselines interpretables.

10.4. Cuándo Graph ML agrega valor

Una GNN está justificada cuando la relación entre nodos aporta señal que no capturan los atributos individuales y cuando el despliegue permite observar esa relación. Antes de entrenarla conviene responder cuatro preguntas:

1. **¿Cuál es la unidad de generalización?** Etiquetas nuevas en el mismo grafo, nodos nuevos, enlaces futuros y grafos completos exigen particiones distintas.
2. **¿La arista tiene un mecanismo defendible?** Una red construida por un umbral arbitrario puede hacer que message passing propague ruido con gran eficiencia.
3. **¿Existe señal incremental?** El modelo debe superar atributos sin topología, centralidades explícitas y heurísticas estructurales bajo el mismo corte.
4. **¿La complejidad mejora la decisión?** Una ganancia pequeña puede no compensar latencia, mantenimiento, falta de calibración o dificultad de explicación.

La comparación debe seguir una escalera, no enfrentar de inmediato una GNN con azar:

1. prevalencia, promedio histórico o ranking aleatorio;
2. modelo tabular con atributos del nodo;
3. modelo tabular con features de red construidas sin leakage;
4. heurísticas específicas de la tarea, como vecinos comunes, Jaccard o Adamic–Adar en predicción de enlaces (Liben-Nowell and Kleinberg, 2007);
5. embeddings congelados y clasificador simple;
6. GNN bajo el mismo presupuesto de ajuste.

La GNN no es la opción adecuada cuando la topología cambia antes del despliegue, los enlaces se observan después de la etiqueta, domina la heterofilia no modelada, hay pocos grafos independientes o un baseline interpretable iguala su rendimiento. Comparaciones controladas muestran que arquitectura, partición y presupuesto de búsqueda pueden alterar el ranking entre modelos (Shchur et al., 2018; Errica et al., 2020). Una evaluación honesta puede concluir que el grafo ayuda, pero que la GNN no.

10.4.1. Casos industriales y criterio de éxito

En fraude, una red de cuentas, dispositivos y transacciones puede revelar coordinación; el éxito se mide en precisión entre los casos que una unidad puede revisar, no solo en AUC. En recomendación, el conjunto de candidatos y la exposición previa determinan negativos y sesgo de popularidad. En bioinformática, la clasificación de moléculas opera sobre grafos independientes y exige splits que eviten compartir scaffolds entre entrenamiento y prueba. El dominio cambia la frontera de información; no la corrige la arquitectura.

10.5. Tareas supervisadas y no supervisadas

Clasificación de nodos. En problemas de clasificación semisupervisada, se observa un conjunto de nodos etiquetados $V_L \subset V$ y se busca inferir etiquetas para $V \setminus V_L$. Dado un embedding h_i, un clasificador softmax produce una distribución $p(y \mid h_i)$ y la pérdida típica combina entropía cruzada sobre V_L con regularizadores de suavizado que penalizan diferencias de representaciones entre nodos conectados (Kipf and Welling, 2017).

Predicción de enlaces. En la tarea de link prediction se entrena un modelo que, a partir de embeddings h_i y h_j, devuelve una puntuación $\sigma(h_i, h_j)$ (por ejemplo, producto escalar o MLP). La pérdida se define sobre pares de aristas observadas y no observadas; esto se utiliza en redes de recomendación y detección de anomalias (Grover and Leskovec, 2016; Kipf and Welling, 2016).

Detección de comunidades. Aunque la detección de comunidades se aborda tradicionalmente mediante criterios de modularidad o blockmodels, los embeddings permiten aproximar una partición latente: se aplica clustering (por ejemplo, k-means) sobre h_i o se optimiza un autoencoder de grafos para maximizar la modularidad (Mucha et al., 2010). Los modelos variacionales (VGAE) implementan funciones de decodificación de aristas y generan agrupaciones implícitas (Kipf and Welling, 2016).

Clasificación de grafos. Cuando las instancias son grafos completos (químicos, redes funcionales), se requiere una operación de *pooling* para resumir nodos en un vector fijo. Métodos como Set2Set, SortPool, DiffPool y Graph U-Nets aprenden a combinar representaciones nodales en un descriptor global (Ying et al., 2018; Yoo et al., 2020). La pérdida se calcula sobre etiquetas a nivel de grafo.

10.6. Cierre: representación antes que arquitectura

Los paseos aleatorios y el *message passing* convierten estructura en representaciones, pero optimizan objetivos diferentes. La arquitectura debe corresponder al tipo de grafo, al régimen de generalización y al mecanismo que hace informativas las aristas. Profundidad, atención o heterogeneidad no sustituyen baselines estructurales ni una partición sin filtración. El modelo más complejo merece conservarse solo si cambia una decisión bajo una evaluación que reproduce el despliegue. El capítulo siguiente formaliza esa prueba.

Capítulo 11

Evaluación y validación de modelos en grafos

11.1. La partición define la generalización

En un grafo, entrenamiento y prueba pueden compartir vecinos, componentes, periodos e incluso la arista que se intenta predecir. Por ello, una puntuación carece de significado sin el régimen de generalización que la produjo. La primera decisión no es la métrica, sino qué permanecerá desconocido al desplegar el modelo: etiquetas de nodos presentes, nodos nuevos, aristas futuras, subgrafos completos o redes de otro dominio.

La evaluación debe imitar esa frontera de información. Si el uso real predice el futuro, ninguna transformación calculada con eventos futuros puede entrar al entrenamiento. Si el uso real incorpora entidades nuevas, una partición que conserva todos los nodos solo mide interpolación transductiva.

11.2. Construcción del grafo sin filtración

El orden correcto es: dividir las unidades según el escenario, construir con información permitida el grafo de entrenamiento, ajustar las transformaciones y aplicar esas transformaciones a validación y prueba. Calcular antes del corte embeddings, comunidades, estadísticas de normalización o negativos utiliza información que el modelo no tendría al momento de predecir.

En predicción de enlaces, la arista objetivo debe retirarse del grafo usado para producir las características del par. De lo contrario, el *message passing* puede transportar directamente la respuesta. Este problema de inclusión de la arista objetivo puede alterar de manera sustantiva la comparación entre modelos (Zhu et al., 2023).

11.3. Regímenes de partición

11.3.1. Clasificación transductiva de nodos

Todos los nodos y parte de la topología pueden estar disponibles durante el entrenamiento, pero solo algunas etiquetas se observan. El modelo predice etiquetas ocultas dentro del mismo grafo. Las aristas entre nodos de entrenamiento y prueba no constituyen filtración si el protocolo las permite explícitamente; el resultado, sin embargo, no demuestra desempeño en nodos nuevos.

11.3.2. Clasificación inductiva

Los nodos o componentes de prueba se excluyen del ajuste. Este régimen evalúa la capacidad de aplicar la regla aprendida a entidades no observadas, objetivo de arquitecturas inductivas como GraphSAGE (Hamilton et al., 2017). Una separación por nodos puede seguir siendo optimista si las mismas organizaciones, periodos o fuentes de datos aparecen a ambos lados; la unidad de corte debe corresponder al despliegue.

11.3.3. Predicción de enlaces

El conjunto de aristas positivas se divide en entrenamiento, validación y prueba. La remoción puede desconectar el grafo o cambiar grados, por lo que deben documentarse las restricciones usadas para preservar conectividad. Los ejemplos negativos no son datos observados: son pares no enlazados bajo una regla de muestreo. Negativos uniformes suelen ser demasiado fáciles en grafos dispersos y pueden cambiar el ranking entre métodos (Liben-Nowell and Kleinberg, 2007; Li et al., 2023).

Una evaluación útil incluye al menos el conjunto de candidatos que existiría en producción. Si un recomendador solo compara personas de la misma región, evaluar contra pares de regiones incompatibles infla el desempeño sin mejorar la decisión.

11.3.4. Grafos temporales

Sea t_0 el corte. El entrenamiento usa eventos con $t \leq t_0$ y la prueba, eventos posteriores. Las características de nodos, grados y negativos deben calcularse con la historia disponible en cada tiempo. Un solo corte puede depender de una coyuntura; las ventanas rodantes permiten estimar variación temporal. Para enlaces dinámicos, el protocolo debe aclarar si predice la primera aparición, la reaparición o cualquier evento (Poursafaei et al., 2022; Rossi et al., 2021).

11.4. Métricas ligadas a la tarea

11.4.1. Clasificación de nodos

La exactitud puede estar dominada por la clase mayoritaria. Para C clases, el F1 macro promedia el F1 de cada clase,

$$F1_{\text{macro}} = \frac{1}{C} \sum_{c=1}^{C} \frac{2\,\text{precision}_c\,\text{recall}_c}{\text{precision}_c + \text{recall}_c}. \tag{11.1}$$

Esta métrica asigna igual peso a clases frecuentes y raras, pero no incorpora costos de error ni calibración. Si las probabilidades alimentan una decisión, deben evaluarse curvas de calibración y una función de pérdida probabilística además del ranking.

11.4.2. Predicción de enlaces

El AUC-ROC estima la probabilidad de ordenar un positivo por encima de un negativo bajo la distribución de muestreo elegida. Cambiar los negativos cambia el estimando. En grafos muy dispersos, el área bajo la curva precisión–recall refleja mejor la degradación causada por

falsos positivos. Para sistemas que revisan un número limitado de candidatos, las métricas precision@K, recall@K o hits@K conectan el desempeño con la capacidad operativa.

Las métricas deben calcularse sobre el mismo conjunto de candidatos para todos los modelos. No es válido comparar un método evaluado con negativos uniformes y otro con negativos difíciles (Li et al., 2023).

11.5. Baselines y ablaciones

Un modelo de grafos se compara, como mínimo, con:

- una regla no informada, como prevalencia o ranking aleatorio;
- un modelo con atributos pero sin aristas;
- heurísticas estructurales apropiadas, como vecinos comunes, Jaccard o Adamic–Adar para predicción de enlaces;
- un modelo lineal o de árboles con características estructurales explícitas;
- la arquitectura propuesta bajo el mismo corte, candidatos y presupuesto de ajuste.

Las ablaciones responden qué componente produce la ganancia: atributos, topología, temporalidad, profundidad o muestreo. Si una heurística simple iguala a la GNN, el resultado no es un fracaso; indica que la complejidad estructural necesaria para esa tarea es menor de la supuesta.

Este tipo de resultado debe conservarse, no ocultarse. Un *draft* sobre diversificación económica encuentra que medidas locales de relatedness siguen dominando ciertas tareas de entrada, mientras los embeddings aportan en otros objetivos y regímenes (Sturm et al., 2026). La comparación desagregada identifica cuándo la representación compleja agrega información.

11.6. Variabilidad y comparación

Una sola semilla no cuantifica incertidumbre. Deben repetirse inicialización, muestreo de negativos y, cuando el diseño lo permita, la partición. Las diferencias entre modelos se calculan de forma pareada sobre las mismas réplicas. En redes con una sola observación global, la variación entre semillas mide inestabilidad computacional, no variación entre poblaciones.

El conjunto de prueba se reserva para la comparación final. Ajustar arquitectura, umbral o negativos después de observarlo lo convierte en validación. Esta regla es especialmente importante en benchmarks pequeños, donde decisiones repetidas pueden sobreajustar el protocolo aunque ningún gradiente toque las etiquetas de prueba. Evaluaciones controladas de GNN han mostrado que diferencias de split, tuning y baseline pueden pesar tanto como la arquitectura (Shchur et al., 2018; Errica et al., 2020).

11.7. Ficha mínima de reporte

Una evaluación reproducible declara:

1. la tarea, el horizonte y el régimen transductivo o inductivo;

2. las fechas y unidades de cada partición;
3. el grafo disponible en entrenamiento, validación y prueba;
4. la regla de negativos y el conjunto de candidatos;
5. las métricas primarias, el umbral y el costo de errores;
6. los baselines, ablaciones y presupuesto de ajuste;
7. el número de réplicas y la medida de variabilidad;
8. las decisiones que dependen de información futura o externa.

La pregunta final no es si el modelo obtiene una puntuación alta, sino qué desconocido predijo, con qué información y frente a qué alternativa. Solo entonces la métrica describe una capacidad de generalización.

Capítulo 12

Diseño de estudios integrados en ciencia de redes

12.1. De una pregunta sustantiva a una red auditable

Un estudio aplicado no comienza calculando centralidades. Comienza con una pregunta, una unidad de análisis y un mecanismo que justifique representar ciertas relaciones. Este capítulo desarrolla cuatro diseños de estudio para mostrar cómo se conectan construcción de la red, análisis estructural, dinámica y validación.

Los casos son protocolos metodológicos, no resultados empíricos. El proyecto no contiene los conjuntos de datos, códigos ni salidas necesarios para atribuir hallazgos a esos sistemas. Por ello, cada sección separa lo que debería medirse de lo que solo podría concluirse después de ejecutar y validar el análisis.

12.2. Protocolo común

Antes de comparar dominios conviene fijar una secuencia común:

1. **Definir el sistema.** Delimitar población, periodo y unidad observada.
2. **Construir la red.** Especificar nodos, aristas, dirección, peso, tiempo y reglas de exclusión.
3. **Describir cobertura.** Cuantificar nodos y eventos ausentes, duplicados y cambios en el mecanismo de medición.
4. **Elegir un nulo.** Comparar cada estadística con un baseline que conserve las restricciones pertinentes, no con una red arbitraria.
5. **Vincular métrica y proceso.** Justificar por qué grado, intermediación, k-core, comunidades o una representación aprendida responden a la pregunta.
6. **Validar.** Separar datos respetando nodos, aristas y tiempo; medir sensibilidad a decisiones de construcción.
7. **Limitar la conclusión.** Distinguir descripción, predicción, detección de anomalías y atribución causal.

12.3. Caso I: telemetría de ciberseguridad

12.3.1. Representación

Los eventos de una plataforma de detección y respuesta extendida (XDR) pueden representarse como una red temporal, dirigida y heterogénea. Usuarios, dispositivos, procesos y direcciones IP son tipos de nodo distintos; autenticaciones, conexiones o ejecuciones son tipos de arista distintos. Colapsarlos en un solo tipo produce una red fácil de visualizar, pero borra restricciones semánticas. Una formulación heterogénea o multicapa conserva el tipo de relación (Shi et al., 2020).

Cada evento debe conservar una marca temporal. Un peso agregado puede contar frecuencia, volumen o severidad, magnitudes que no son intercambiables. La ventana temporal debe elegirse respecto del proceso de ataque; agregar un mes completo puede fabricar caminos que no respetan el orden de los eventos.

12.3.2. Preguntas y baselines

El análisis descriptivo puede identificar concentración de actividad, cambios de vecindario y aparición de subgrafos inusuales. Una puntuación de anomalía debe compararse con baselines temporales y estructurales: frecuencia histórica por entidad, reglas conocidas, cambios de grado o fuerza y modelos que ignoran la topología. Una GNN solo demuestra utilidad si mejora la detección en eventos futuros o entidades no observadas bajo el mismo costo operativo.

La división aleatoria de eventos filtra patrones del futuro y eventos de una misma entidad hacia entrenamiento y prueba. El corte principal debe ser temporal; una evaluación adicional por entidades mide generalización inductiva. Los problemas de inclusión de la arista objetivo y negativos triviales en predicción de enlaces son especialmente relevantes (Li et al., 2023; Zhu et al., 2023).

12.3.3. Conclusión permitida

Una anomalía estructural es una desviación respecto del baseline, no evidencia de intrusión. La evaluación debe informar precisión entre las primeras alertas, falsos positivos por periodo y tiempo de anticipación, además de métricas agregadas.

12.4. Caso II: copresencia inferida mediante WiFi

12.4.1. De eventos técnicos a vínculos sociales

Dos dispositivos conectados al mismo punto de acceso durante intervalos superpuestos producen evidencia de copresencia, no una observación directa de interacción social. La red depende de la resolución espacial del punto de acceso, la duración mínima, el solapamiento temporal y las reglas para dispositivos múltiples. Cada umbral define una red diferente.

El análisis debe presentar curvas de sensibilidad para densidad, componentes, clustering y estabilidad de comunidades. Las comunidades pueden contrastarse con horarios, cursos o espacios, pero la coincidencia no prueba que representen grupos sociales. La modularidad optimizada necesita comparación con un nulo y estabilidad entre soluciones (Newman, 2006; Fortunato, 2010).

La inferencia de una red informal de repartidores a partir de copresencia GPS ofrece un antecedente publicado para este diseño (Pilatti et al., 2023). Su lección transferible no es que toda copresencia sea un vínculo, sino que la validación debe conectar patrones espaciales, modularidad y resultados externos sin confundir el proxy con la relación latente.

12.4.2. Temporalidad y privacidad

La red agregada pierde secuencias de contacto relevantes para difusión. Un análisis temporal debe exigir caminos con tiempos crecientes y evaluar si los resultados sobreviven a distintas ventanas. Como los patrones de movilidad pueden reidentificar personas aun sin nombres, la minimización de datos y el control de acceso forman parte del diseño analítico, no de una etapa posterior (Narayanan and Shmatikov, 2009; Tufekci, 2014).

12.5. Caso III: trayectorias educativas

12.5.1. Estructura bipartita

Una red estudiante–programa, curso–programa o persona–ocupación conserva dos conjuntos de nodos y aristas que cruzan entre ellos. La proyección sobre programas conecta dos carreras cuando comparten estudiantes, pero los programas grandes generan muchas coincidencias por construcción. Pesos como el número bruto de estudiantes deben compararse con una expectativa que controle los grados de ambos lados (Latapy et al., 2008; Chung et al., 2019).

Si existen semestres, la red debe registrar transiciones y no solo copertenencia. Así es posible distinguir programas que comparten matrícula simultánea de programas conectados por trayectorias secuenciales. La dirección y el tiempo cambian la pregunta.

La construcción del *Higher Education Space* a partir de preferencias reveladas en Chile y Portugal proporciona un caso publicado de esta lógica (Candia et al., 2019a, 2025). Un manuscrito posterior utiliza distancias entre las opciones de cada postulante para estudiar alineamiento y persistencia (Davyt-Colo et al., 2026); se cita como *draft*, no como resultado publicado.

12.5.2. Alcance inferencial

Comunidades o posiciones centrales pueden describir rutas frecuentes y concentración de oportunidades. No identifican barreras ni efectos causales de un programa sin un diseño que trate selección, elegibilidad y confusión. Si se formula una intervención, deben declararse el mapa de exposición y los posibles spillovers según el capítulo 8.

12.6. Caso IV: compras públicas

12.6.1. Red temporal y ponderada

La estructura natural es bipartita entre proveedores e instituciones, con aristas por adjudicación. Monto, número de contratos y tipo de procedimiento son atributos distintos. Una proyección proveedor–proveedor puede medir coparticipación en mercados o instituciones, pero debe normalizar la actividad de compradores grandes y proveedores frecuentes. Los nulos

bipartitos que preservan ambos márgenes proporcionan una referencia más coherente que recablear únicamente la proyección (Lyra et al., 2021).

La concentración se evalúa con distribuciones de monto y participación, estructura núcleo–periferia y persistencia temporal. Un patrón núcleo–periferia debe estimarse y compararse con modelos alternativos; no basta una inspección visual (Yanchenko and Sengupta, 2023). Los cambios regulatorios y presupuestarios requieren baselines por periodo y categoría.

Dos estudios publicados ofrecen baselines complementarios. El primero estima leyes de escalamiento para comparar actividad de compra entre municipios de distinto tamaño (Curado et al., 2021); el segundo relaciona posición en redes de colicitación con ganancias por oferta bajo modelos de panel (Sturm et al., 2025). Un *draft* adicional compara relatedness y embeddings para predecir diversificación (Sturm et al., 2026). Ninguno convierte una puntuación estructural en evidencia de irregularidad.

12.6.2. Detección sin acusación

Triángulos, concentración o recurrencia pueden priorizar revisiones, pero no establecen ilegalidad. El sistema debe reportar por qué una observación fue priorizada, contra qué grupo comparable se midió y cuántos casos puede revisar una persona. La validación relevante es la utilidad para ordenar inspecciones bajo capacidad limitada, junto con una auditoría de sesgos por tamaño, región y sector.

12.7. Tres extensiones para Graph ML industrial

12.7.1. Fraude coordinado

La unidad de análisis puede ser una cuenta, una transacción o un subgrafo de entidades que comparten dispositivos, direcciones o beneficiarios. Mezclar esas unidades en una etiqueta única produce leakage: un identificador compartido puede revelar el caso investigado. La división debe agrupar entidades relacionadas y respetar el tiempo. El criterio de éxito es el rendimiento en la fracción que puede revisar un equipo, acompañado por calibración y falsos positivos por segmento.

12.7.2. Recomendación

La ausencia de una arista usuario–ítem no equivale a rechazo; puede significar que el ítem nunca fue expuesto. El conjunto de negativos y candidatos define la tarea. Vecinos comunes, Jaccard y modelos de factores constituyen baselines antes de introducir message passing (Liben-Nowell and Kleinberg, 2007). Un split aleatorio de interacciones repetidas permite que el historial futuro del mismo usuario entre al entrenamiento; el corte temporal evita esa filtración.

12.7.3. Bioinformática

En clasificación molecular, cada molécula es un grafo y la generalización ocurre hacia grafos no observados. Separar moléculas casi idénticas entre entrenamiento y prueba puede medir memorización de scaffolds. Las arquitecturas se comparan bajo el mismo split, presupuesto y baseline químico; sin esa disciplina, la diferencia atribuida a una GNN puede provenir del protocolo (Errica et al., 2020).

12.8. Síntesis transversal

Los cuatro diseños comparten una disciplina: la red observada no es el sistema, sino una medición del sistema. En XDR, el tiempo separa alerta retrospectiva de detección anticipada; en WiFi, la copresencia no equivale a interacción; en educación, una proyección puede confundir tamaño con afinidad; en compras públicas, una anomalía no equivale a conducta ilícita. El aporte de la ciencia de redes aparece cuando representación, modelo nulo, proceso y validación responden a la misma pregunta.

La misma disciplina se observa en aplicaciones publicadas a cooperación escolar, desempeño, bullying y deliberación ciudadana (Pulgar et al., 2020; Candia et al., 2022; Landaeta-Torres et al., 2024; Raveau et al., 2022): la métrica adquiere sentido por el diseño que produjo la red y por la variable externa contra la cual se contrasta.

Capítulo 13

Ética y privacidad en redes

13.1. Medir redes como acto de poder

13.1.1. Intuición: de lo local a lo global

Una persona puede entregar un solo vínculo y revelar, junto con otros registros, una comunidad completa. Quien construye la red decide qué interacción cuenta, quién queda visible y qué posición recibe un nombre como «central» o «periférica» (Clauset, 2022). Esa asimetría distingue los datos relacionales: una arista informa sobre sus dos extremos y modifica lo que puede inferirse sobre vecinos que quizá nunca consintieron participar.

13.1.2. De la re-identificación a la manipulación de algoritmos

Aunque se anonimicen nombres y atributos, la estructura puede bastar para reidentificar personas. Los ataques que alinean dos redes parcialmente superpuestas explotan vecindarios y patrones relacionales como cuasi-identificadores (Narayanan and Shmatikov, 2009; Backstrom et al., 2007). Por ello, sustituir identificadores directos no convierte una red sensible en un conjunto anónimo. El riesgo depende de la información auxiliar disponible y debe evaluarse para el adversario plausible, no para un lector que solo posee el archivo publicado.

13.2. Privacidad, homofilia y filtrado

13.2.1. Homofilia y fuga de información

La homofilia —la asociación entre similitud y formación de vínculos— aparece en muchos contextos sociales (McPherson et al., 2001). Si un atributo se correlaciona con el vecindario, las etiquetas observadas de algunos nodos pueden ayudar a inferir las de otros. La magnitud de esa fuga no es universal: depende del atributo, la cobertura, la red y el modelo. El punto ético permanece aun cuando la predicción sea imperfecta: una persona no controla la información que sus vecinos revelan sobre ella.

13.2.2. Ataques de inferencia y modelos de filtrado

Label propagation usa etiquetas observadas para estimar las de nodos próximos; una GNN aprende una regla de agregación más flexible (Hamilton, 2020). La misma capacidad que mejora una clasificación puede reconstruir afiliación política, salud u otro atributo no declarado cuando

existe homofilia. En recomendación, el filtrado colaborativo enfrenta un riesgo adicional: la exposición producida por el sistema modifica los datos con los que se reentrena. Popularidad y segregación pueden entonces reforzarse sin una regla explícita que las ordene (Barocas and Selbst, 2016).

13.3. Buenas prácticas y principios éticos

13.3.1. Anonimización y minimización de daños

Antes de compartir una red deben eliminarse datos innecesarios y evaluarse ataques de reidentificación. Permutar identificadores o perturbar aristas puede reducir utilidad sin ofrecer una garantía formal (Hay et al., 2008). Un mecanismo aleatorio M satisface ϵ-privacidad diferencial de aristas si, para grafos G y G' que difieren en una arista y para todo conjunto de resultados medibles S,

$$\Pr[M(G) \in S] \leq e^{\epsilon} \Pr[M(G') \in S]. \tag{13.1}$$

La privacidad de nodos protege la inclusión de todas las aristas incidentes a una persona y es una noción más exigente (Kasiviswanathan et al., 2013; Zhou et al., 2016). La garantía cubre el mecanismo y la relación de adyacencia declarada; no vuelve inocuo cualquier uso posterior.

13.3.2. Consentimiento informado y transparencia

El protocolo debe especificar finalidad, retención, acceso, destinatarios y mecanismo de retiro cuando corresponda. Los requisitos legales dependen de la jurisdicción y del tipo de dato; la obligación ética no desaparece porque una API permita técnicamente la descarga. Licencia, expectativas contextuales y riesgo de reidentificación se evalúan por separado (Tufekci, 2014). En salud, sexualidad o persecución política, publicar una subred puede exponer más que publicar una tabla de atributos.

13.3.3. Equidad algorítmica y mitigación de sesgos

Una recomendación de empleo entrenada sobre homofilia puede concentrar exposición en las comunidades que ya reciben oportunidades. La auditoría debe separar error, exposición y resultado por grupo; una sola paridad agregada puede ocultar perjuicios en el ranking (Barocas and Selbst, 2016; Chouldechova, 2017). Regularizadores adversarios y técnicas de *debiasing* reducen ciertas dependencias con atributos sensibles, pero no corrigen una red que representa de forma desigual a la población (Bose et al., 2019).

13.3.4. Directrices institucionales y deontología

Los requisitos institucionales y legales dependen de la jurisdicción, el tipo de dato y la finalidad del tratamiento. El protocolo debe identificar la base de acceso, la retención, los responsables, los destinatarios y el procedimiento de retiro cuando corresponda. Una API pública no equivale a consentimiento para cualquier investigación; representatividad, expectativas contextuales y riesgo de amplificación siguen siendo problemas metodológicos y éticos (Tufekci, 2014).

La exigencia aumenta con poblaciones y atributos sensibles. Redes de cooperación y bullying en niños (Candia et al., 2022; Landaeta-Torres et al., 2024) y datos que combinan violencia con

movilidad (Contreras et al., 2023) muestran dominios donde una red desidentificada todavía puede exponer relaciones, ubicaciones o vulnerabilidades. La publicación debe evaluarse a nivel del grafo y de las combinaciones posibles, no solo de cada columna.

13.4. Ética del aprendizaje automático en grafos

Un embedding puede codificar un atributo sensible que nunca apareció como columna. El message passing transporta información correlacionada entre vecinos; retirar el atributo del vector de entrada no elimina esa vía. La auditoría debe probar inferencia de atributos desde las representaciones y medir desempeño por grupo antes y después de usar topología.

La trazabilidad también cambia. Una predicción nodal depende de atributos propios, vecindario, profundidad y muestreo. Explicar solo las features del nodo omite parte del cálculo. Cuando una decisión afecta empleo, crédito, salud o vigilancia, deben conservarse la versión del grafo, los vecinos disponibles al predecir y el baseline sin información relacional.

13.5. Conclusiones

La privacidad relacional no puede resolverse nodo por nodo. Una arista revela información sobre dos extremos y puede modificar inferencias sobre un vecindario completo. El diseño responsable comienza reduciendo la recolección, restringiendo acceso y declarando usos; continúa con pruebas de reidentificación, evaluación de sesgos y controles de salida. La pregunta decisiva no es si una red puede analizarse, sino qué daño hace posible al combinar estructura, atributos y modelos.

Bibliografía

Backstrom, L., Dwork, C., and Kleinberg, J. (2007). Wherefore art thou r3579x? anonymized social networks, hidden patterns, and structural re-identification. In *Proceedings of the 16th International Conference on World Wide Web*, pages 181–190.

Barabási, A.-L. and Albert, R. (1999). Emergence of scaling in random networks. *Science*, 286(5439):509–512.

Barabási, A.-L. and Pósfai, M. (2016). *Network Science*. Cambridge University Press, Cambridge.

Barocas, S. and Selbst, A. D. (2016). Big data's disparate impact. In *California Law Review*, volume 104, pages 671–732. Discusses algorithmic discrimination and fairness, applicable to graph-based recommender systems.

Barrat, A., Barthélemy, M., and Vespignani, A. (2008). *Dynamical Processes on Complex Networks*. Cambridge University Press, Cambridge.

Blondel, V. D., Guillaume, J.-L., Lambiotte, R., and Lefebvre, E. (2008). Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, 2008(10):P10008.

Bo, D., Wang, X., Yu, A., Gong, Y., Shi, C., Guo, J., and Liang, Y. (2021). Beyond homophily in graph neural networks: Current limitations and effective designs. *Proceedings of the Conference on Neural Information Processing Systems (NeurIPS)*.

Borgatti, S. P. (2005). Centrality and network flow. *Social Networks*, 27(1):55–71.

Borgatti, S. P. and Everett, M. G. (2000). Models of core/periphery structures. *Social Networks*, 21(4):375–395.

Bose, A. J., Hamilton, W. L., and Compton, R. (2019). Compositional fairness constraints for graph embedding. In *Proceedings of the 36th International Conference on Machine Learning*, pages 715–724. Proposes fairness constraints for embeddings in graphs.

Candia, C. (2025). Quantifying the temporal dynamics of collective memory and attention in social systems. In Yasseri, T., editor, *Handbook of Computational Social Science*, pages 636–651. Edward Elgar Publishing.

Candia, C., Encarnação, S., and Pinheiro, F. L. (2019a). The higher education space: Connecting degree programs from individuals' choices. *EPJ Data Science*, 8(1):39.

Candia, C., Jara-Figueroa, C., Rodriguez-Sickert, C., Barabási, A.-L., and Hidalgo, C. A. (2019b). The universal decay of collective memory and attention. *Nature Human Behaviour*, 3(1):82–91.

Candia, C., Oyarzún, M., Landaeta, V., Yaikin, T., Monge, C., Hidalgo, C. A., and Rodriguez-Sickert, C. (2022). Reciprocity heightens academic performance in elementary school students. *Heliyon*, 8(12):e11916.

Candia, C., Pulgar, J., and Pinheiro, F. L. (2025). Interconnectedness in education systems. In Yasseri, T., editor, *Handbook of Computational Social Science*, pages 891–909. Edward Elgar Publishing.

Candia, C. and Uzzi, B. (2021). Quantifying the selective forgetting and integration of ideas in science and technology. *American Psychologist*, 76(6):1067–1087.

Chouldechova, A. (2017). Fair prediction with disparate impact: A study of bias in recidivism prediction instruments. *Big Data*, 5(2):153–163.

Chung, N. C., Miasojedow, B., Startek, M., and Gambin, A. (2019). Jaccard/tanimoto similarity test and estimation methods for biological presence–absence data. *BMC Bioinformatics*, 20:644.

Clauset, A. (2022). Ethics and the science of networks. Notas de clase. Discusses power dynamics and ethical dilemmas in network measurement and analysis.

Cohen, R., Havlin, S., and ben Avraham, D. (2003). Efficient immunization strategies for computer networks and populations. *Physical Review Letters*, 91(24):247901.

Contreras, H., Candia, C., Troncoso, R., Ferres, L., Bravo, L., Lepri, B., and Rodriguez-Sickert, C. (2023). Linking physical violence to women's mobility in Chile. *EPJ Data Science*, 12(1):54.

Curado, A., Damásio, B., Encarnação, S., Candia, C., and Pinheiro, F. L. (2021). Scaling behavior of public procurement activity. *PLOS ONE*, 16(12):e0260806.

Davyt-Colo, J., Pinheiro, F. L., Pulgar, J., Guevara, M., Rodriguez-Sickert, C., and Candia, C. (2026). Preference alignment shapes persistence under constrained choice. Unpublished manuscript (draft, 30 June 2026).

Errica, F., Podda, M., Bacciu, D., and Micheli, A. (2020). A fair comparison of graph neural networks for graph classification. In *International Conference on Learning Representations*.

Fortunato, S. (2010). Community detection in graphs. *Physics Reports*, 486:75–174.

Freeman, L. C. (1978). Centrality in social networks: Conceptual clarification. *Social Networks*, 1(3):215–239.

Fuentes-Jofre, A., Jara-Figueroa, C., and Candia, C. (2026). Revealed policy choices uncover latent ideological geometry across societies. Unpublished manuscript (draft, 2 July 2026).

Gotelli, N. J. (2000). Null model analysis of species co-occurrence patterns. *Ecology*, 81(9):2606–2621.

Granovetter, M. S. (1973). The strength of weak ties. *American Journal of Sociology*, 78(6):1360–1380.

Grover, A. and Leskovec, J. (2016). node2vec: Scalable feature learning for networks. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 855–864. ACM.

Hamilton, W. L. (2020). *Graph Representation Learning*, volume 14 of *Synthesis Lectures on Artificial Intelligence and Machine Learning*. Morgan & Claypool Publishers.

Hamilton, W. L., Ying, R., and Leskovec, J. (2017). Inductive representation learning on large graphs. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 1024–1034.

Hay, M., Li, G., Miklau, G., and Jensen, D. (2008). Resisting structural re-identification in anonymized social networks. *Proceedings of the VLDB Endowment*, 1(1):102–114.

Herrera, M., Candia, C., Rivera, D., Aitken, D., Brieba, D., Boettiger, C., Donoso, G., and Godoy-Faúndez, A. (2019). Understanding water disputes in Chile with text and data mining tools. *Water International*, 44(3):302–320.

Herrera-Guzmán, Y., Gates, A. J., Candia, C., and Barabási, A.-L. (2023). Quantifying hierarchy and prestige in US ballet academies as social predictors of career success. *Scientific Reports*, 13(1):18594.

Karrer, B. and Newman, M. E. J. (2010). Message passing approach for general epidemic models. *Physical Review E*, 82(1):016101.

Kasiviswanathan, S. P., Nissim, K., Raskhodnikova, S., and Smith, A. (2013). Analyzing graphs with node differential privacy. *The Theory of Cryptography Conference (TCC)*, 7194:457–476. Introduces node differential privacy and mechanisms for graph data.

Kempe, D., Kleinberg, J., and Tardos, É. (2015). Maximizing the spread of influence through a social network. *Theory of Computing*, 11(4):105–147. Extended version of KDD 2003 paper.

Kipf, T. N. and Welling, M. (2016). Variational graph auto-encoders. *NIPS Workshop on Bayesian Deep Learning*. arXiv:1611.07308.

Kipf, T. N. and Welling, M. (2017). Semi-supervised classification with graph convolutional networks. In *Proceedings of the International Conference on Learning Representations (ICLR)*. arXiv:1609.02907.

Kitsak, M., Gallos, L. K., Havlin, S., Liljeros, F., Muchnik, L., Stanley, H. E., and Makse, H. A. (2010). Identification of influential spreaders in complex networks. *Nature Physics*, 6:888–893.

Landaeta-Torres, V., Candia, C., Pulgar, J., Fábrega, J., Varela, J. J., Yaikin, T., Monge, C., and Rodriguez-Sickert, C. (2024). Game theory in the classroom: Low cooperative relationships identify bullying patterns in elementary schools. *Humanities and Social Sciences Communications*, 11(1):1101.

Latapy, M., Magnien, C., and Del Vecchio, N. (2008). Basic notions for the analysis of large two-mode networks. *Social Networks*, 30(1):31–48.

Li, J., Shomer, H., Mao, H., Zeng, S., Ma, Y., Shah, N., Tang, J., and Yin, D. (2023). Evaluating graph neural networks for link prediction: Current pitfalls and new benchmarking. In *Advances in Neural Information Processing Systems 36 (Datasets and Benchmarks Track)*.

Liben-Nowell, D. and Kleinberg, J. (2007). The link-prediction problem for social networks. *Journal of the American Society for Information Science and Technology*, 58(7):1019–1031.

Lyra, M. S., Curado, A., Damásio, B., Bação, F., and Pinheiro, F. L. (2021). Characterization of the firm-firm public procurement co-bidding network from the state of ceará municipalities. *Applied Network Science*, 6:77.

McPherson, M., Smith-Lovin, L., and Cook, J. M. (2001). Birds of a feather: Homophily in social networks. *Annual Review of Sociology*, 27:415–444.

Menczer, F., Fortunato, S., and Davis, C. A. (2020). *A First Course in Network Science*. Cambridge University Press, Cambridge.

Mucha, P. J., Richardson, T., Macon, K., Porter, M. A., and Onnela, J.-P. (2010). Community structure in time-dependent, multiscale, and multiplex networks. *Science*, 328(5980):876–878.

Narayanan, A. and Shmatikov, V. (2009). De-anonymizing social networks. *Proceedings of the 30th IEEE Symposium on Security and Privacy*, pages 173–187.

Newman, M. (2010). *Networks: An Introduction*. Oxford University Press, Oxford.

Newman, M. E. (2006). Modularity and community structure in networks. *Proceedings of the national academy of sciences*, 103(23):8577–8582.

Newman, M. E. J. (2000). Models of the small world: A review. https://arxiv.org/abs/cond-mat/0001118. arXiv preprint cond-mat/0001118.

Newman, M. E. J. (2001). Scientific collaboration networks. i. network construction and fundamental results. *Physical Review E*, 64(1):016131.

Newman, M. E. J. (2002). Spread of epidemic disease on networks. *Physical Review E*, 66(1):016128.

Newman, M. E. J. (2003). The structure and function of complex networks. *SIAM Review*, 45(2):167–256.

Newman, M. E. J. (2018). *Networks*. Oxford University Press, Oxford, 2 edition.

Newman, M. E. J., Strogatz, S. H., and Watts, D. J. (2001). Random graphs with arbitrary degree distributions and their applications. *Physical Review E*, 64(2):026118.

Oyarzún, M., Rodriguez-Sickert, C., and Candia, C. (2026). Friendship modulates the expression of hierarchy in cooperation. Unpublished manuscript (draft, 2 July 2026).

Page, L., Brin, S., Motwani, R., and Winograd, T. (1999). The PageRank citation ranking: Bringing order to the web. Technical Report 1999-66, Stanford InfoLab.

Pastor-Satorras, R., Castellano, C., Mieghem, P. V., and Vespignani, A. (2015). Epidemic processes in complex networks. *Reviews of Modern Physics*, 87:925–979.

Pastor-Satorras, R. and Vespignani, A. (2002). Immunization of complex networks. *Physical Review E*, 65(3):036104.

Perozzi, B., Al-Rfou, R., and Skiena, S. (2014). Deepwalk: Online learning of social representations. *Proceedings of the 20th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 701–710.

Pilatti, G., Candia, C., Montini, A., and Pinheiro, F. L. (2023). From co-location patterns to an informal social network of gig economy workers. *Applied Network Science*, 8(1):77.

Poursafaei, F. et al. (2022). Towards better evaluation for dynamic link prediction. In *NeurIPS Datasets and Benchmarks Workshop*.

Pulgar, J., Candia, C., and Leonardi, P. M. (2020). Social networks and academic performance in physics: Undergraduate cooperation enhances ill-structured problem elaboration and inhibits well-structured problem solving. *Physical Review Physics Education Research*, 16(1):010137.

Pulgar, J., Órdenes-Escobar, M., Ramírez, D., and Candia, C. (2025). Balancing friendship and exploration: Grouping strategies and their impact on classroom dynamics. *The Journal of Experimental Education*, pages 1–19.

Pulgar, J., Ramírez, D., and Candia, C. (2023). Enhanced social connectivity in hybrid classrooms versus academic centrality in online settings. *Physical Review Physics Education Research*, 19(2):020155.

Pulgar, J., Ramírez, D., Umanzor, A., Candia, C., and Sánchez, I. (2022). Long-term collaboration with strong friendship ties improves academic performance in remote and hybrid teaching modalities in high school physics. *Physical Review Physics Education Research*, 18(1):010146.

Ramírez, D., Guzmán-Lavín, E. J., Pulgar, J., and Candia, C. (2025). Self-select groups increase stability but reduce collaboration in high school physics. *Physical Review Physics Education Research*, 21(1):010157.

Raveau, M. P., Couyoumdjian, J. P., Fuentes-Bravo, C., Rodriguez-Sickert, C., and Candia, C. (2022). Citizens at the forefront of the constitutional debate: Voluntary citizen participation determinants and emergent content in Chile. *PLOS ONE*, 17(6):e0267443.

Raveau, M. P., Couyoumdjian, J. P., Fuentes-Bravo, C., Rodriguez-Sickert, C., and Candia, C. (2024). The lexical divide: Propositive modes and non-agentic attitudes define the progressive left in Chile. *Humanities and Social Sciences Communications*, 11(1):908.

Rodrigues, F. A. (2018). Network centrality: an introduction. In Macau, E. E. N., editor, *A Mathematical Modeling Approach from Nonlinear Dynamics to Complex Systems*, volume 9 of *Nonlinear Systems and Complexity*, pages 177–196. Springer.

Rossi, E., Chamberlain, B., Frasca, F., King, O., Bronstein, M., and Monti, F. (2021). Temporal graph networks for deep learning on dynamic graphs. *Proceedings of the International Conference on Machine Learning (ICML)*. arXiv:2006.10637.

Rossi, R. A. and Ahmed, N. K. (2015). Role discovery in networks. *IEEE Transactions on Knowledge and Data Engineering*, 27(4):1112–1131.

Shchur, O., Mumme, M., Bojchevski, A., and Günnemann, S. (2018). Pitfalls of graph neural network evaluation. In *Relational Representation Learning Workshop, NeurIPS*.

Shi, C., Kong, X., Kuang, Y., Wang, M., and Sun, Y. (2020). Heterogeneous graph neural network. *Proceedings of the 2019 World Wide Web Conference*, pages 1054–1064.

Sturm, N. F., Candia, C., Damásio, B., and Pinheiro, F. L. (2025). High earnings through firm influence: The role of hierarchical structures in public procurement. *EPJ Data Science*, 14(1):27.

Sturm, N. F., Candia, C., Damásio, B., and Pinheiro, F. L. (2026). The latent structure of diversification from relatedness and network embeddings. Unpublished manuscript (draft, 2 July 2026).

Sánchez-Lengeling, B., Reif, E., Pearce, A., and Wiltschko, A. B. (2021). A gentle introduction to graph neural networks. *Distill*, 6(9):e33.

Tang, J., Qu, M., Wang, M., Zhang, J. Y., Qin, B., and Mei, Q. (2015). Line: Large-scale information network embedding. *Proceedings of the 24th International Conference on World Wide Web*, pages 1067–1077.

Traag, V. A., Waltman, L., and van Eck, N. J. (2019). From Louvain to Leiden: Guaranteeing well-connected communities. *Scientific Reports*, 9:5233.

Tufekci, Z. (2014). Big questions for social media big data: Representativeness, validity and other methodological pitfalls. *Proceedings of the International AAAI Conference on Web and Social Media*, 8:505–514. Addresses ethical issues in using public social media data.

Van Mieghem, P., Omic, J., and Kooij, R. (2009). Virus spread in networks. *IEEE/ACM Transactions on Networking*, 17(1):1–14.

Veličković, P., Cucurull, G., Casanova, A. R., Liò, P., and Bengio, Y. (2018). Graph attention networks. *Proceedings of the International Conference on Learning Representations (ICLR)*. arXiv:1710.10903.

Wasserman, S. and Faust, K. (1994). *Social Network Analysis: Methods and Applications*. Cambridge University Press, Cambridge, UK.

Watts, D. J. and Strogatz, S. H. (1998). Collective dynamics of 'small-world' networks. *Nature*, 393:440–442.

Yanchenko, E. and Sengupta, S. (2023). Core-periphery structure in networks: a statistical exposition. *Statistics Surveys*, 17:42–74. arXiv preprint arXiv:2202.04455.

Ying, R., You, J., Morris, C., Ren, X., Hamilton, W. L., and Leskovec, J. (2018). Hierarchical graph representation learning with differentiable pooling. In *Advances in Neural Information Processing Systems (NeurIPS)*, pages 4805–4815.

Yoo, Y., Shi, X., Collins, M., and Zust, J. (2020). Graph u-nets for graph neural network based graph classification. *arXiv preprint arXiv:1905.05178*. arXiv:1905.05178.

Zhou, B., Bu, Z., Wang, C., Gao, S., Li, K., Cao, Q., and Song, D. (2016). Edge differential privacy for social network data publishing. *IEEE Transactions on Knowledge and Data Engineering*, 28(9):2413–2423.

Zhu, J., Zhou, Y., Ioannidis, V. N., Qian, S., Ai, W., Song, X., and Koutra, D. (2023). Pitfalls in link prediction with graph neural networks: Understanding the impact of target-link inclusion & better practices. *arXiv preprint*.